

BTC 강화학습 그리드 트레이딩에서 Reward 함수 설계의 영향:

Pareto 프론티어, Winner Reversal, 그리고 Prospect Theory의 분포 외 강건성

이찬희 (Lee Chanhee)

컴퓨터공학부

서울과학기술대학교

happilyfly@seoultech.ac.kr

2026년 6월

Abstract

본 논문은 BTC/USDT 1시간봉 시장에서 가격 방향 예측 없이 ATR(Average True Range) 비레 지정가 그리드를 결정하는 PPO 기반 강화학습 정책에 대해 *reward* 함수 설계가 정책의 행동 패턴과 일반화 성능에 미치는 영향을 정량 검증한다. 4가지 reward 변형 — 대칭 보상(sym), 비대칭 보상(asym, $\beta = 3.42$), 미분 샤프 비율(dsr, $\eta = 1/28h$), 프로스펙트 이론 보상(pt, $\alpha = 0.68, \lambda = 3.30$) — 을 동일 환경에서 각각 10 시드 $\times$ 100만 스텝 학습 후, (i) 단일 분할 검증 (Val 2021–2023), (ii) 6중 CPCV(Combinatorial Purged CV) 15-path 평가, (iii) 봉인 해제된 테스트 셋(Test 2024–2026) 분포 외 평가의 세 환경에서 비교한다.

주요 발견: (1) Val에서 4개 변형이 ATR 기반 베이스라인(Val Sharpe ≈ 1.38 –1.51)을 모두 +11 ~ 24% 초과하나 단일 winner는 없으며, 두 클러스터 {sym, dsr}(공격적) vs {asym, pt}(보수적)로 통계적으로 분리된다(그룹 내 $|d| < 0.3$, 그룹 간 $|d| > 0.8$). (2) Reward 형식이 정책의 거래 빈도와 holding 시간을 직접 결정하며 (정책 거리 비율 2.22배), dsr의 hold rate가 다른 변형의 2–6배인 것이 sliding-window reward 자체의 메모리 구조 결과임을 정량 확인한다. (3) 평가 환경별로 winner가 reversal: Val의 sym(1.87) $\rightarrow$ CPCV의 dsr(1.41, $p < 0.001$) $\rightarrow$ Test의 pt(0.34–0.37, 두 소스 일관 $p < 0.002$). (4) pt의 분포 외 강건성 메커니즘: $\lambda = 3.30$ 손실 회피와 $\alpha = 0.68$ 오목한 효용함수가 정책의 매수 후 평균 1.4시간(최대 6시간) 빠른 청산을 학습시켜 미관측 강세장(BTC \$42K $\rightarrow$ \$76K)의 매도 타이밍 위험을 회피한다. 반면 dsr은 평균 4.58시간(최대 169시간 = 7일) holding을 학습시켜 동일 환경에서 최악 성능 기록. (5) Val–Test 분포 차이가 통계적으로 매우 유의(KS $p < 10^{-10}$, 변동성 +27%) 하며, 모든 정책의 Val/Test 행동은 거의 동일($\Delta \text{action} \leq 5\%$)이므로 OOS 성능 차이는 정책이 아닌 시장 분포 이동이 직접 원인이다.

본 연구의 학술적 기여는 reward 설계의 효과가 단일 Sharpe metric의 “alpha source”가 아니라 *risk profile* 차원의 *trade-off* + 평가 환경별 *winner reversal*로 나타남을 정량 보이는 것이며, Kahneman과 Tversky(1979)의 prospect theory가 강화학습 정책에 부여하는 분포 외 안전성을 첫 정량 확인한 것이다. 코드와 데이터: <https://github.com/cosmicpotato2047/capstone-rl-trading>.

키워드: 강화학습, 그리드 트레이딩, PPO, Reward Design, Prospect Theory, Differential Sharpe Ratio, CPCV, 분포 외 일반화, 암호화폐

Abstract (English)

We quantitatively study the effect of *reward function design* on PPO-based RL policies for ATR-proportional grid trading on the BTC/USDT 1-hour market. Four reward variants—symmetric (**sym**), asymmetric ($\beta = 3.42$, **asym**), Differential Sharpe Ratio ($\eta = 1/28$ h, **dsr**), and prospect-theoretic ($\alpha = 0.68$, $\lambda = 3.30$, **pt**)—are each trained with 10 seeds $\times$ 1M steps and evaluated on three environments: (i) single-split validation (Val 2021–2023), (ii) 6-fold CPCV 15 paths, and (iii) the unsealed out-of-sample Test (2024–2026, BTC \$42K $\rightarrow$ \$76K).

Key findings: (1) All four variants exceed the ATR baseline by +11–24% on Val, but partition into two clusters {**sym**, **dsr**} (aggressive) vs. {**asym**, **pt**} (conservative); within-cluster $|d| < 0.3$ vs. across-cluster $|d| > 0.8$. (2) Mechanism: reward asymmetry directly determines trade frequency and holding time (policy distance ratio 2.22 $\times$), and the sliding-window memory of DSR results in 2–6 $\times$ higher hold rate. (3) Winner reverses across evaluation environments: Val=**sym**(1.87) $\rightarrow$ CPCV=**dsr**(1.41, $p < 0.001$) $\rightarrow$ Test=**pt**(0.34–0.37, consistent across two sources, $p < 0.002$). (4) Mechanism for **pt**'s OOS robustness: short holding (mean 1.4 h, max 6 h) avoids sell-side timing risk in the unseen bull market. In contrast, **dsr** learns long holding (mean 4.58 h, max 169 h = 7 days) and records the worst OOS performance, showing that the same reward formulation drives both in-sample advantage and OOS failure as two sides of the same coin. (5) Val–Test distribution shift is statistically significant (KS $p < 10^{-10}$, –27% variance), while policy actions remain nearly invariant ($\Delta \leq 5\%$) between Val and Test, indicating the regime shift, not the policy, drives OOS differences. Our main contribution is the quantitative demonstration that reward design exerts its effect through the trade-off dimension rather than a single Sharpe “alpha source,” and provides the first quantitative evidence that Kahneman-Tversky prospect theory confers OOS safety on RL trading policies.

Contents

1	서론	4
1.1	동기와 연구 질문	4
1.2	기여 사항	4
1.3	본 논문 구성	5
2	관련 연구	5
3	방법론	5
4	Phase 1: 대칭 보상 하의 정책 포화	5
5	Pareto 프론티어와 시나리오 D	5
6	메커니즘 정량화	5
7	강건성 분석	6
7.1	Slippage 강건성	6
7.2	CPCV 다중 split 평가	6
7.3	분포 외 평가와 Prospect Theory의 강건성	6
8	논의	6
9	결론	6

1 서론

BTC 등 암호화폐 시장의 시간봉 가격 변동은 장기 추세와 무관한 빈번한 미세 진동 (micro-oscillation)이 본질적 특성으로, 이 변동성 자체를 수익원으로 삼는 그리드 트레이딩(grid trading)은 시장 조성(market making) [Avellaneda and Stoikov, 2008]의 단순화된 변형이다. 고정된 가격 격자 위에 매수/매도 주문을 정기적으로 배치하는 단순한 규칙 기반 전략부터, ATR(Average True Range) [Wilder, 1978] 비례로 격자 폭을 동적 조정하는 변동성 적응형 변형까지 다양한 구현이 존재한다. 본 연구는 후자, 즉 ATR 비례 그리드 트레이딩의 격자 폭과 체결 가격을 강화학습 정책으로 결정하는 시스템을 다룬다.

1.1 동기와 연구 질문

본 시스템의 초기 가설(2026년 1-3월 작업)은 “PPO 강화학습이 동적 변동성 적응을 학습하여 고정 그리드 베이스라인을 초과한다”였다. 그러나 사후 분석 결과 학습된 정책이 사실상 상수 액션 [1.0, 0.0]으로 수렴함이 확인되었고 (§4 상세), Bayesian으로 최적화된 ATR 계수 자체가 성능의 주요 원동력임이 드러났다. 이 negative finding은 대칭 보상(symmetric reward) + ATR 비례 공식의 조합이 RL 정책의 자유도를 본질적으로 흡수한다는 가설로 이어졌고, 본 논문의 새 연구 질문을 동기화한다:

BTC 그리드 트레이딩에서 reward 함수의 설계가 RL 정책의 행동 패턴과 일반화 성능에 어떤 영향을 미치는가? 특히, 손실 비대칭(asymmetric, prospect-theoretic) 또는 위험 조정 수익(DSR) 형태의 reward 정식화가 단일 metric 상위 또는 분포 외(out-of-sample) 강건성 측면에서 의미 있는 차이를 만드는가?

1.2 기여 사항

본 논문의 학술적 기여는 다음 네 가지이다.

1. **Reward 변형의 통계적으로 엄밀한 비교 프레임워크**: 4가지 reward 함수(sym, asym, dsr, pt)를 동일 환경에서 10 시드 × 100만 스텝으로 학습하고, Cohen’s d , 부트스트랩 $P(A > B)$, IQM, 5% CVaR을 사용하여 페어와이즈 통계 검정을 수행한다.
2. **시나리오 D — Pareto 프론티어 발견**: 단순 “X reward가 best”의 단일 winner 결론 대신, 4 변형이 {sym, dsr}와 {asym, pt}의 두 클러스터로 통계적으로 분리되어 Sharpe-MDD 평면에서 Pareto-유사 프론티어를 형성함을 보이며 (§5), 이는 사전에 설정한 시나리오 분기(낙관 A/중립 B/비관 C) 어디에도 해당하지 않는 새로운 결과 형태이다.
3. **Reward → 행동 → 결과의 인과 사슬 정량**: 변형 간 정책 행동의 차이를 1.04M step trajectory 위에서 정책 거리 행렬(within-cluster 0.129 vs. across-cluster 0.286), regime별 거래/holding 통계, 행동 분포 비교로 정량화하여 “reward 형식의 손실 비대칭 → 거래 빈도 감소 → 보수적 클러스터”의 메커니즘을 확인한다 (§6).
4. **평가 환경별 winner reversal과 Prospect Theory의 OOS 강건성**: Single-split Val(sym 1위) → CPCV multi-split(dsr 1위) → 봉인 해제된 Test(pt 1위, 두 소스 일관 $p < 0.002$)의 세 환경에서 winner가 완전 reversal한다 (§7). pt의 OOS 강건성 메커니즘은 prospect theory의 손실 회피 $\lambda = 3.30$ 과 오목 효용 $\alpha = 0.68$ 이 정책의 holding을 매우 짧게(평균 1.4시간) 학습시켜 미관측 강세장의 매도 타이밍 위험을 회피하는 결과임을 trajectory 분석으로 입증한다.

이는 Kahneman과 Tversky(1979)의 이론이 강화학습 정책에 부여하는 분포 외 안전성의 첫 정량 확인이다.

1.3 본 논문 구성

§2는 RL 트레이딩, reward 설계 이론, 평가 방법론의 선행 연구를 정리한다. §3는 환경 설계 (MDP, ATR 공식, 4 reward 변형)와 PPO 학습 설정을 기술한다. §4는 본 연구의 동기인 Phase 1 negative finding("RL = Fixed [1.0, 0.0]")을 간략 재인용한다. §5는 Val에서의 두 클러스터 발견(시나리오 D)을, §6은 메커니즘 정량을 다룬다. §7은 slippage 견고성(§7.1), CPCV 다중 split(§7.2), 그리고 본 논문의 핵심인 Test OOS와 prospect theory의 강건성 메커니즘(§7.3)을 다룬다. §8은 분포 이동의 정량과 한계를 논의하며, §9에서 마무리한다.

2 관련 연구

[TBD: 추후 작성. PAPER_OUTLINE의 §2 매핑. 서브 섹션: 시장 조성/그리드 트레이딩 (Avellaneda-Stoikov 2008), DRL 트레이딩 (Zhang-Zohren-Roberts 2020, Gort 2022, Sun 2023, Liu 2025), Reward 설계 이론 (Moody-Saffell 2001 DSR, Kahneman-Tversky 1979 PT, Ng 1999 reward shaping), 평가 방법론 (López de Prado 2018 CPCV, 2014 DSR, Henderson 2018 reproducibility).]

3 방법론

[TBD: 추후 작성. 서브 섹션: §3.1 MDP 설계 (State 7D, Action 2D, ATR 비례 공식), §3.2 Trading 환경 구체 (사이클, fee, slippage), §3.3 4 reward 변형 정의 + Optuna 튜닝 (exp032a), §3.4 PPO 안정화 패키지 (target_kl, ent annealing), §3.5 평가 방법론 (Val/CPCV/Test).]

4 Phase 1: 대칭 보상 하의 정책 포화

[TBD: 추후 작성. exp020-022의 "RL = Fixed [1.0, 0.0]" 발견. 대칭 보상 + ATR 비례 공식 조합의 RL 자유도 흡수. 본 논문의 reward 정식화 동기.]

5 Pareto 프론티어와 시나리오 D

[TBD: 추후 작성. exp032b 결과: 4 variants $\times$ 10 seeds 통계, Pareto scatter, 두 클러스터 (aggressive/conservative), 가설 H1-H3 점검, 시나리오 D 확정.]

6 메커니즘 정량화

[TBD: 추후 작성. exp032c 결과: Policy distance 행렬, behavior per regime, counterfactual action map, action distribution. 인과 사슬: reward 형식 $\rightarrow$ 거래 빈도 $\rightarrow$ 클러스터.]

7 강건성 분석

7.1 Slippage 강건성

[TBD: 추후 작성. *exp033*: 4 variants $\times$ 10 seeds with slippage 0.02%. Cluster preservation ratio 2.19 $\times$. ATR-with-slippage fair 비교 결과 (Phase 16a).]

7.2 CPCV 다중 split 평가

[TBD: 추후 작성. *exp034*: 6-fold CPCV 15 paths. DSR $p < 0.001$ (Bonferroni 4-way 보정), *dss* variant reversal 1위 (1.413, 5% CVaR 0.890), Cluster ratio 3.55 $\times$.]

7.3 분포 외 평가와 Prospect Theory의 강건성

[TBD: 추후 작성. 본 논문의 핵심 챕터. *exp035*: 100 RL models + ATR baseline + Buy-and-Hold Test. *pt*의 Test 1위 (두 소스 $p < 0.002$), *dss*의 Test 꼴찌. Phase 16d mechanism: holding 시간 분포 (DSR 7-day max vs. *pt* 6h max). *pt*의 분포 외 강건성의 인과 사슬.]

8 논의

[TBD: 추후 작성. 서브 섹션: §8.1 Val-Test 분포 이동의 정량 ($KS\ p < 10^{-10}$, -27% variance), §8.2 *exp027_rl* 사전 증거 (*Env-v3 asym* 1.955)의 환경 의존성 정직 인정, §8.3 단일 metric winner의 한계, §8.4 한계: BTC 단일 자산, Test 1 regime, single slippage level.]

9 결론

[TBD: 추후 작성. 4개 메인 메시지: (1) Pareto 프론티어 trade-off, (2) 평가 환경별 winner reversal, (3) Prospect Theory의 OOS 강건성, (4) In-sample 우위 $\neq$ OOS 강건성. Future work: multi-asset, regime, DR, meta-RL.]

References

Marco Avellaneda and Sasha Stoikov. High-frequency trading in a limit order book. *Quantitative Finance*, 8(3):217–224, 2008. doi: 10.1080/14697680701381228.

J. Welles Wilder. New concepts in technical trading systems. 1978.