

BTC 강화학습 그리드 트레이딩에서 Reward 함수 설계의 영향:

Pareto 프론티어, Winner Reversal, 그리고 Prospect Theory의 분포 외 강건성

이찬희 (Lee Chanhee)

컴퓨터공학부

서울과학기술대학교

happilyfly@seoultech.ac.kr

2026년 6월

Abstract

본 논문은 BTC/USDT 1시간봉 시장에서 가격 방향 예측 없이 ATR(Average True Range) 비레 지정가 그리드를 결정하는 PPO 기반 강화학습 정책에 대해 *reward* 함수 설계가 정책의 행동 패턴과 일반화 성능에 미치는 영향을 정량 검증한다. 4가지 reward 변형 — 대칭 보상 (sym), 비대칭 보상 (asym, $\beta = 3.42$), 미분 샤프 비율 (dsr, $\eta = 1/28$ h), 프로스펙트 이론 보상 (pt, $\alpha = 0.68, \lambda = 3.30$) — 을 동일 환경에서 각각 10 시드 $\times$ 100만 스텝 학습 후, (i) 단일 분할 검증 (Val 2021–2023), (ii) 6중 CPCV(Combinatorial Purged CV) 15-path 평가, (iii) 봉인 해제된 테스트 셋(Test 2024–2026) 분포 외 평가의 세 환경에서 비교한다.

주요 발견: (1) Val에서 4개 변형이 ATR 기반 베이스라인(Val Sharpe ≈ 1.38 –1.51)을 모두 +11 ~ 24% 초과하나 단일 winner는 없으며, 두 클러스터 {sym, dsr}(공격적) vs {asym, pt}(보수적)로 통계적으로 분리된다(그룹 내 $|d| < 0.3$, 그룹 간 $|d| > 0.8$). (2) Reward 형식이 정책의 거래 빈도와 holding 시간을 직접 결정하며 (정책 거리 비율 2.22배), dsr의 hold rate가 다른 변형의 2–6배인 것이 sliding-window reward 자체의 메모리 구조 결과임을 정량 확인한다. (3) 평가 환경별로 winner가 reversal: Val의 sym(1.87) $\rightarrow$ CPCV의 dsr(1.41, $p < 0.001$) $\rightarrow$ Test의 pt(0.34–0.37, 두 소스 일관 $p < 0.002$). (4) pt의 분포 외 강건성 메커니즘: $\lambda = 3.30$ 손실 회피와 $\alpha = 0.68$ 오목한 효용함수가 정책의 매수 후 평균 1.4시간(최대 6시간) 빠른 청산을 학습시켜 미관측 강세장(BTC \$42K $\rightarrow$ \$76K)의 매도 타이밍 위험을 회피한다. 반면 dsr은 평균 4.58시간(최대 169시간 = 7일) holding을 학습시켜 동일 환경에서 최악 성능 기록. (5) Val–Test 분포 차이가 통계적으로 매우 유의(KS $p < 10^{-10}$, 변동성 +27%) 하며, 모든 정책의 Val/Test 행동은 거의 동일(Δ action $\leq 5\%$)이므로 OOS 성능 차이는 정책이 아닌 시장 분포 이동이 직접 원인이다.

본 연구의 학술적 기여는 reward 설계의 효과가 단일 Sharpe metric의 “alpha source”가 아니라 *risk profile* 차원의 *trade-off* + 평가 환경별 *winner reversal*로 나타남을 정량 보이는 것이며, Kahneman과 Tversky(1979)의 prospect theory가 강화학습 정책에 부여하는 분포 외 안전성을 첫 정량 확인한 것이다. 코드와 데이터: <https://github.com/cosmicpotato2047/capstone-rl-trading>.

키워드: 강화학습, 그리드 트레이딩, PPO, Reward Design, Prospect Theory, Differential Sharpe Ratio, CPCV, 분포 외 일반화, 암호화폐

Abstract (English)

We quantitatively study the effect of *reward function design* on PPO-based RL policies for ATR-proportional grid trading on the BTC/USDT 1-hour market. Four reward variants—symmetric (**sym**), asymmetric ($\beta = 3.42$, **asym**), Differential Sharpe Ratio ($\eta = 1/28$ h, **dsr**), and prospect-theoretic ($\alpha = 0.68$, $\lambda = 3.30$, **pt**)—are each trained with 10 seeds $\times$ 1M steps and evaluated on three environments: (i) single-split validation (Val 2021–2023), (ii) 6-fold CPCV 15 paths, and (iii) the unsealed out-of-sample Test (2024–2026, BTC \$42K $\rightarrow$ \$76K).

Key findings: (1) All four variants exceed the ATR baseline by +11–24% on Val, but partition into two clusters {**sym**, **dsr**} (aggressive) vs. {**asym**, **pt**} (conservative); within-cluster $|d| < 0.3$ vs. across-cluster $|d| > 0.8$. (2) Mechanism: reward asymmetry directly determines trade frequency and holding time (policy distance ratio 2.22 $\times$), and the sliding-window memory of DSR results in 2–6 $\times$ higher hold rate. (3) Winner reverses across evaluation environments: Val=**sym**(1.87) $\rightarrow$ CPCV=**dsr**(1.41, $p < 0.001$) $\rightarrow$ Test=**pt**(0.34–0.37, consistent across two sources, $p < 0.002$). (4) Mechanism for **pt**'s OOS robustness: short holding (mean 1.4 h, max 6 h) avoids sell-side timing risk in the unseen bull market. In contrast, **dsr** learns long holding (mean 4.58 h, max 169 h = 7 days) and records the worst OOS performance, showing that the same reward formulation drives both in-sample advantage and OOS failure as two sides of the same coin. (5) Val–Test distribution shift is statistically significant (KS $p < 10^{-10}$, –27% variance), while policy actions remain nearly invariant ($\Delta \leq 5\%$) between Val and Test, indicating the regime shift, not the policy, drives OOS differences. Our main contribution is the quantitative demonstration that reward design exerts its effect through the trade-off dimension rather than a single Sharpe “alpha source,” and provides the first quantitative evidence that Kahneman-Tversky prospect theory confers OOS safety on RL trading policies.

Contents

1	서론	5
1.1	동기와 연구 질문	5
1.2	기여 사항	5
1.3	본 논문 구성	6
2	관련 연구	6
2.1	시장 구성과 그리드 트레이딩	6
2.2	강화학습 기반 트레이딩	6
2.3	Reward 설계 이론	7
2.4	평가 방법론	8
3	방법론	8
3.1	MDP 정의	8
3.2	Trading 환경의 동역학	10
3.3	ATR 베이스라인	11
3.4	4가지 Reward 변형	11
3.5	PPO 학습 구성과 안정화 패키지	12
3.6	평가 프로토콜	13
4	Phase 1: 대칭 보상 하의 정책 포화	13
4.1	정책 포화 현상	14
4.2	결정적 Ablation: "RL = Fixed [1.0, 0.0]"	14
4.3	메커니즘 해석: ATR 공식이 자유도를 흡수한다	15
4.4	본 논문의 동기	15
5	Pareto 프론티어와 시나리오 D	15
5.1	실험 설정	15
5.2	Per-variant 결과: 4 metric 1위가 모두 다르다	16
5.3	Pareto 프론티어 시각화	16
5.4	두 클러스터의 통계적 분리	16
5.5	정책 거리: 행동 수준의 클러스터 확인	17
5.6	시나리오 D 확정과 가설 점검	18
5.7	exp027_rl 사전 증거의 환경 의존성	19
6	메커니즘 정량화	19
7	강건성 분석	20
7.1	Slippage 강건성	20
7.2	CPCV 다중 split 평가	20
7.3	분포 외 평가와 Prospect Theory의 강건성	20
8	논의	20

1 서론

BTC 등 암호화폐 시장의 시간봉 가격 변동은 장기 추세와 무관한 빈번한 미세 진동 (micro-oscillation)이 본질적 특성으로, 이 변동성 자체를 수익원으로 삼는 그리드 트레이딩(grid trading)은 시장 조성(market making) [Avellaneda and Stoikov, 2008]의 단순화된 변형이다. 고정된 가격격자 위에 매수/매도 주문을 정기적으로 배치하는 단순한 규칙 기반 전략부터, ATR(Average True Range) [Wilder, 1978] 비례로 격자 폭을 동적 조정하는 변동성 적응형 변형까지 다양한 구현이 존재한다. 본 연구는 후자, 즉 ATR 비례 그리드 트레이딩의 격자 폭과 체결 가격을 강화학습 정책으로 결정하는 시스템을 다룬다.

1.1 동기와 연구 질문

본 시스템의 초기 가설(2026년 1-3월 작업)은 “PPO 강화학습이 동적 변동성 적응을 학습하여 고정 그리드 베이스라인을 초과한다”였다. 그러나 사후 분석 결과 학습된 정책이 사실상 상수 액션 [1.0, 0.0]으로 수렴함이 확인되었고 (§4 상세), Bayesian으로 최적화된 ATR 계수 자체가 성능의 주요 원동력임이 드러났다. 이 negative finding은 대칭 보상(symmetric reward) + ATR 비례 공식의 조합이 RL 정책의 자유도를 본질적으로 흡수한다는 가설로 이어졌고, 본 논문의 새 연구 질문을 동기화한다:

**BTC 그리드 트레이딩에서 reward 함수의 설계가 RL 정책의 행동 패턴과 일
반화 성능에 어떤 영향을 미치는가? 특히, 손실 비대칭(asymmetric, prospect-
theoretic) 또는 위험 조정 수익(DSR) 형태의 reward 정식화가 단일 metric 상위
또는 분포 외(out-of-sample) 강건성 측면에서 의미 있는 차이를 만드는가?**

1.2 기여 사항

본 논문의 학술적 기여는 다음 네 가지이다.

1. **Reward 변형의 통계적으로 엄밀한 비교 프레임워크**: 4가지 reward 함수(sym, asym, dsr, pt)를 동일 환경에서 10 시드 × 100만 스텝으로 학습하고, Cohen’s d , 부트스트랩 $P(A > B)$, IQM, 5% CVaR을 사용하여 페어와이즈 통계 검정을 수행한다.
2. **시나리오 D — Pareto 프론티어 발견**: 단순 “X reward가 best”의 단일 winner 결론 대신, 4 변형이 {sym, dsr}와 {asym, pt}의 두 클러스터로 통계적으로 분리되어 Sharpe-MDD 평면에서 Pareto-유사 프론티어를 형성함을 보이며 (§5), 이는 사전에 설정한 시나리오 분기(낙관 A/중립 B/비관 C) 어디에도 해당하지 않는 새로운 결과 형태이다.
3. **Reward → 행동 → 결과의 인과 사슬 정량**: 변형 간 정책 행동의 차이를 1.04M step trajectory 위에서 정책 거리 행렬(within-cluster 0.129 vs. across-cluster 0.286), regime별 거래/holding 통계, 행동 분포 비교로 정량화하여 “reward 형식의 손실 비대칭 → 거래 빈도 감소 → 보수적 클러스터”의 메커니즘을 확인한다 (§6).
4. **평가 환경별 winner reversal과 Prospect Theory의 OOS 강건성**: Single-split Val(sym 1위) → CPCV multi-split(dsr 1위) → 봉인 해제된 Test(pt 1위, 두 소스 일관 $p < 0.002$)의 세 환경에서 winner가 완전 reversal한다 (§7). pt의 OOS 강건성 메커니즘은 prospect theory의 손실 회피 $\lambda = 3.30$ 과 오목 효용 $\alpha = 0.68$ 이 정책의 holding을 매우 짧게(평균 1.4시간) 학습시켜 미관측 강세장의 매도 타이밍 위험을 회피하는 결과임을 trajectory 분석으로 입증한다.

이는 Kahneman과 Tversky(1979)의 이론이 강화학습 정책에 부여하는 분포 외 안전성의 첫 정량 확인이다.

1.3 본 논문 구성

§2는 RL 트레이딩, reward 설계 이론, 평가 방법론의 선행 연구를 정리한다. §3는 환경 설계(MDP, ATR 공식, 4 reward 변형)와 PPO 학습 설정을 기술한다. §4는 본 연구의 동기인 Phase 1 negative finding("RL = Fixed [1.0, 0.0]")을 간략 재인용한다. §5는 Val에서의 두 클러스터 발견(시나리오 D)을, §6은 메커니즘 정량을 다룬다. §7은 slippage 견고성(§7.1), CPCV 다중 split(§7.2), 그리고 본 논문의 핵심인 Test OOS와 prospect theory의 강건성 메커니즘(§7.3)을 다룬다. §8은 분포 이동의 정량과 한계를 논의하며, §9에서 마무리한다.

2 관련 연구

본 연구는 (i) 시장 조성 and 그리드 트레이딩, (ii) 강화학습 기반 트레이딩, (iii) reward 설계 이론, (iv) 트레이딩 정책의 평가 방법론의 네 분야 교차점에 위치한다. 이 절은 각 분야의 핵심 선행 연구를 정리하고, 본 논문이 차지하는 좌표를 명시한다.

2.1 시장 조성 and 그리드 트레이딩

그리드 트레이딩의 학술적 조상은 Avellaneda and Stoikov [2008]의 시장 조성 (market making) 모델이다. 이 연구는 위험 회피적 시장 조성자가 재고 위험(inventory risk)에 직면할 때, 중심 가격(mid-price)을 중심으로 매수/매도 호가를 대칭적이지 않게 배치하는 최적 정책의 폐형 해(closed-form solution)를 유도한다. 핵심 통찰은 (a) 호가의 폭(spread)이 변동성과 시간 잔여량의 함수로 결정되며, (b) 재고 편향(inventory skew)이 호가 중심을 비대칭적으로 이동시킨다는 것이다. 그리드 트레이딩은 이 모델의 단순화된 실용 변형으로, 고정 간격 격자에 주문을 미리 배치하여 미세 변동성을 수익화한다.

격자 폭을 시장 변동성에 적응시키는 표준 방법은 Wilder [1978]의 ATR(Average True Range, 14일 이동평균 윈도우 표준)을 사용하는 것이다. ATR은 실제 변동 폭(true range)의 평활 평균으로 변동성 클러스터링(volatility clustering) 구간에서 격자 폭을 자동 확장하는 단순하고도 견고한 규칙을 제공한다. ATR 비례 그리드 ($\Delta = c \cdot \text{ATR}$, c = 비례 계수)는 실무에서 널리 사용되며, 본 연구의 베이스라인이기도 하다.

이 분야의 기존 학술 연구는 대부분 규칙 기반(rule-based) 정책의 분석에 머물러 있으며, 격자 폭 결정을 데이터로부터 학습하는 시도는 제한적이다. 본 논문은 ATR 비례 공식의 비례 계수와 격자 분할 수를 강화학습 정책으로 동적 결정하는 구조를 채택하면서도, 동시에 reward 함수 설계가 학습된 정책의 행동에 어떤 영향을 미치는지 정량적으로 분석한다는 점에서 차별성을 가진다.

2.2 강화학습 기반 트레이딩

암호화폐 시장에 대한 DRL 트레이딩의 표준 베이스라인은 Zhang et al. [2020]이 제시한 PPO/A2C/DQN 비교 프레임워크이다. 이 연구는 가격 시계열을 입력으로 직접 받는 PPO 정책이 단순 buy-and-hold(B&H)와 무빙 평균 교차 전략을 일관적으로 초과하는 결과를 보였다. Sun et al. [2023]의 ACM Transactions 서베이와 Liu [2025]의 최근 리뷰는 이 분야의 두 가지 미해결

과제로 (a) 정책 행동의 해석 가능성, (b) 시장 레짐 간 일반화를 지적한다. 본 논문은 이 두 과제를 직접 다룬다: §6에서 reward 형식에서 행동 차이로 가는 인과 사슬을 정량화하며, §7에서 단일 분할 검증으로 잡히지 않는 분포 외(OOS) 일반화 현상을 보고한다.

직접 선행 연구는 네 편이다. Liu et al. [2020]은 LSTM 가격 예측의 출력을 PPO 정책의 state로 입력하는 2단계 구조를 제안했다. 이 접근의 한계는 예측 오류가 정책 결정에 그대로 전파된다는 점이며, 본 논문은 가격 예측 단계를 완전 제거한 변동성 적응형 그리드 구조로 이 한계를 우회한다. Yasin and Gill [2024]은 DQN/PPO/A2C 세 알고리즘과 20개 기술지표를 비교하나, action 공간이 이산 buy/sell이고 holding 행동이 없는 한계가 있다. 본 논문은 연속 2차원 action(공격성과 이익 목표)을 채택해 그리드의 미세 조정을 가능하게 한다. Pham et al. [2025]은 사전 정의된 5개 전략 중 하나를 DQN으로 선택하는 메타-전략 구조이나, 전략 자체는 학습되지 않는다. Bandarupalli [2025]는 PPO에 변동성 패널티와 거래 비용 항을 추가하나, 단일 reward 변형의 hyperparameter 조정 수준에 머물러 본 논문이 다루는 reward 형식 자체의 비교는 포함하지 않는다.

특히 중요한 선행 연구는 Gort et al. [2022]이다. 이 논문은 암호화폐 DRL 트레이딩에서 단일 train/test 분할의 결과가 OOS 일반화를 보장하지 않는다는 실증을 제시하며, CPCV(Combinatorial Purged Cross-Validation)와 DSR(Deflated Sharpe Ratio)을 권장한다. 본 논문은 Gort et al.의 평가 권장사항을 채택하여 Val (2021–2023) / CPCV 6-fold (Train 분할 내부) / Test (2024–봉인 해제) 세 환경을 동시에 사용한다. 본 논문의 winner reversal 발견(Val sym → CPCV dsr → Test pt)은 Gort et al.의 우려가 reward 변형 선택의 차원에서도 동일하게 나타남을 정량 확인한 것이다.

본 논문의 위치를 한 줄로 요약하면: 기존 DRL 트레이딩 문헌이 단일 reward 함수의 알고리즘/state 설계 비교에 집중한 반면, 본 논문은 같은 알고리즘 (PPO)과 같은 환경 위에서 reward 함수 자체의 4가지 변형을 통제 비교하며, 그 효과를 in-sample / multi-split / OOS 세 환경에서 분리 측정한다.

2.3 Reward 설계 이론

본 논문이 비교하는 4가지 reward 변형은 강화학습과 행동경제학의 세 가지 이론적 계보에서 도출된다. (i) 대칭(sym)은 표준 PnL 수익률 reward로 비교 베이스라인 역할을 한다. (ii) 비대칭(asym)은 손실에 양의 가중치 $\beta > 1$ 을 부여하는 변형으로, 위험 회피 효용 함수의 단순 1차 근사이다. (iii) 미분 샤프 비율(dsr)은 Moody and Saffell [2001]의 정식이다. (iv) 프로스펙트 이론 보상(pt)은 Kahneman and Tversky [1979]과 Tversky and Kahneman [1992]의 효용 함수 $v(x) = \text{sgn}(x)|x|^\alpha$ ($x \geq 0$ 일 때) 또는 $-\lambda|x|^\alpha$ ($x < 0$ 일 때)를 단계 reward로 직접 사용한다.

Moody and Saffell [2001]의 DSR은 샤프 비율의 온라인 추정치 변화량을 step reward로 사용하는 정식으로, 지수 가중 이동 평균(EWMA, decay rate η)으로 1차와 2차 모멘트를 추적한다. 이 정식은 강화학습 정책 학습에 두 가지 의미를 갖는다: (a) 단순 PnL 대비 위험 조정 수익을 직접 최적화한다, (b) sliding window의 메모리 구조가 정책에 단일 step 이상의 시간 의존성을 부여한다. 본 논문 §6은 이 메모리 구조의 결과로 dsr 변형의 정책이 다른 변형 대비 2–6배 긴 holding 시간을 학습함을 정량 확인하며, 이는 §7의 in-sample 다중 분할에서의 우위와 §7.3의 OOS 실패로 이어지는 인과의 출발점이다.

Kahneman and Tversky [1979]의 프로스펙트 이론은 인간 의사 결정의 위험 행동을 설명하는 행동경제학 기초이며, 특히 (a) 손실 회피 $\lambda \approx 2.25$ (Tversky and Kahneman 1992의 표준값), (b) 효용 함수의 오목성 $\alpha \approx 0.88$ 이 핵심 모수이다. 이 이론은 인간 트레이더의 행동(예: “손실에 매달리고 이익은 빨리 실현”)을 설명하는 데는 광범위하게 사용되어 왔으나, 강화학습 정책의 *reward*로 직접 사용한 학술 연구는 매우 드물다. 본 논문은 Kahneman and Tversky [1979]의 정식을 RL reward로 직접 구현하고 ($\alpha = 0.68$, $\lambda = 3.30$, Optuna로 튜닝), 이 reward로 학습된 정책이 분포 외 환경에서 보이는 강건성을 정량적으로 입증한다는 점에서, 본 논문이 알기로는 첫 사례에 해당한다.

Ng et al. [1999]의 정책 불변 reward shaping(potential-based shaping) 정리는 “보상의 단조 변환은 정책 학습 결과에 영향을 미치지 않는다”는 결론을 도출한다. 얼핏 본 논문의 4 reward 변형 비교가 이 정리와 충돌하는 듯 보이지만, 그렇지 않다: $\text{sym} \rightarrow \text{asym}/\text{pt}$ 의 변환은 음의 영역에 비대칭 스케일을 부여하는 비-*potential-based* 변환이며, *dsr*은 단순 step reward 변환이 아닌 *state-extended* reward(즉, sliding window 모멘트가 사실상 state의 일부)이다. 따라서 본 논문의 reward 변형 비교는 Ng et al.의 정리의 적용 범위 밖에 있으며, 실제로 변형 간 정책 행동이 통계적으로 유의하게 차이남을 §6에서 확인한다.

2.4 평가 방법론

강화학습 정책의 평가에서 가장 큰 함정은 (a) 백테스트 과적합과 (b) 결과의 시드 의존성이다. Henderson et al. [2018]는 동일 알고리즘이라도 시드 차이만으로 결과가 크게 변동함을 실증하고, 5-10 시드의 통계적 비교, IQM (Interquartile Mean), 부트스트랩 신뢰구간을 표준 권장사항으로 제시했다. 본 논문은 변형당 10 시드(Val/exp033), 100 모델(Test)을 사용하며 페어와이즈 Cohen’s d 와 부트스트랩 $P(A > B)$ 를 모든 비교에 적용한다.

López de Prado [2018] (8장)의 *Combinatorial Purged Cross-Validation*(CPCV)은 시계열 데이터에서 train/test 누설을 방지하면서 $\binom{N}{k}$ 개의 분할 조합을 활용하여 단일 분할 결과의 일반화 가능성을 강화하는 방법이다. 본 논문은 6-fold CPCV(15 paths)를 §7.2에서 채택한다.

Bailey and López de Prado [2014]의 *Deflated Sharpe Ratio*(DSR*)는 백테스트 시도 횟수와 분포의 첨도/왜도를 보정한 샤프 비율의 통계적 유의성 검정이다. 본 논문은 CPCV 결과의 다중 비교에 Bonferroni 보정 4-way + DSR* 검정을 함께 사용하며 (§7.2), 모든 reward 변형이 ATR 대비 $p < 0.001$ 의 유의성을 만족함을 확인한다.

본 논문의 평가 방법론 측면 차별점은 세 환경(Val / CPCV / Test)을 동시에 사용하여 *winner reversal*을 발견한 점이다. 단일 분할 또는 CPCV 단독을 사용하는 기존 연구는 OOS 일반화 실패를 발견할 수 없으며, OOS만 사용하는 연구는 pt 변형의 in-sample 보수성을 발견할 수 없다. 세 환경의 동시 적용은 Henderson et al. [2018]와 Gort et al. [2022]이 권장하는 복수 평가 방식을 *reward* 변형 비교라는 단일 차원에 일관 적용한 점에서 방법론적 기여를 가진다.

3 방법론

3.1 MDP 정의

본 연구는 BTC/USDT 1시간봉 가격 시계열 위에서 단일 자산 동적 그리드 트레이딩을 유한-수명(finite-horizon) 마르코프 결정 과정 $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \gamma)$ 으로 정식화한다. 한 에피소드는

학습/검증 구간 내부에서 무작위 시작 시점부터 720시간(30일)간 진행되며, 각 step t 는 1시간 가격봉을 의미한다.

State $\mathcal{S} \subset \mathbb{R}^7$. 관측 $s_t = (s_t^{(0)}, \dots, s_t^{(6)})$ 의 각 성분은 시장 상태와 포지션 상태를 함께 포착한다.

$$s_t^{(0)} = \log(p_t / \bar{p}_{t,168}) \quad (\text{가격 추세 vs 1주 평균}) \quad (1)$$

$$s_t^{(1)} = \frac{\bar{p}_t^{\text{avg}} - p_t}{\bar{p}_t^{\text{avg}}} \quad (\text{평단가 대비 괴리율}) \quad (2)$$

$$s_t^{(2)} = \frac{h_t \cdot p_t}{C_0} \quad (\text{자본 대비 포지션 비율}) \quad (3)$$

$$s_t^{(3)} = \frac{c_t}{C_0} \quad (\text{현금 비율}) \quad (4)$$

$$s_t^{(4)} = \frac{\text{ATR}_{168}(p)}{p_t} \quad (\text{변동성}) \quad (5)$$

$$s_t^{(5)} = \frac{p_t - p_{t-72}}{p_{t-72}} \quad (\text{단기 추세, 3일}) \quad (6)$$

$$s_t^{(6)} = \frac{p_t - p_{t-720}}{p_{t-720}} \quad (\text{장기 추세, 30일}) \quad (7)$$

여기서 p_t 는 봉 종가, $\bar{p}_t^{\text{avg}}$ 는 현재 보유분의 평단가(미보유 시 0으로 대체되어 $s_t^{(1)}$ 도 0), h_t 는 BTC 보유 수량, c_t 는 현금 잔고, $C_0 = 10,000$ USDT는 초기 자본이다. ATR_{168} 은 Wilder [1978]의 평균진실범위(168봉 = 1주일 윈도우)이며, $\bar{p}_{t,168}$ 은 168봉 단순이동평균이다. 모든 성분은 학습 셋 위에서 계산한 168-봉 rolling z-score로 사전 정규화한 뒤 $[-5, 5]$ 로 클리핑한다.

Action $\mathcal{A} = [0, 1]^2$. 정책은 매 step 2차원 연속 action $\mathbf{a}_t = (a_t^{(0)}, a_t^{(1)})$ 를 출력한다. $a_t^{(0)}$ (공격성, aggressiveness)은 매수 호가 두 개를, $a_t^{(1)}$ (이익 목표, profit_target)은 매도 호가 두 개를 결정한다. 이산 buy/sell/hold action을 사용하지 않는 이유는 그리드의 미세 폭 조정과 변동성 적응 모두 연속값으로 자연스럽게 표현되기 때문이며, 이산화는 행동 공간의 표현력을 인위적으로 제한한다.

ATR-비례 격자 공식. 격자의 폭과 위치는 변동성 정규화된 행동 좌표를 통해 결정된다. 현재 가격 p_t , $r_t = \text{ATR}_{168}(p)/p_t$, 평단가 $\bar{p}_t^{\text{avg}}$ 에 대해:

$$g_t^{\text{buy_hi}} = r_t \cdot (A_b + B_b \cdot a_t^{(0)}) \quad (8)$$

$$g_t^{\text{buy_lo}} = r_t \cdot (C_b + D_b \cdot a_t^{(0)}) \quad (9)$$

$$g_t^{\text{sell_mkt}} = r_t \cdot (A_s + B_s \cdot a_t^{(1)}) \quad (10)$$

$$g_t^{\text{sell_cost}} = r_t \cdot (C_s + D_s \cdot a_t^{(1)}) \quad (11)$$

호가 가격:

$$q_t^{\text{buy_hi}} = p_t(1 - g_t^{\text{buy_hi}}), \quad q_t^{\text{buy_lo}} = p_t(1 - g_t^{\text{buy_lo}}) \quad (12)$$

$$q_t^{\text{sell_mkt}} = p_t(1 + g_t^{\text{sell_mkt}}), \quad q_t^{\text{sell_cost}} = \bar{p}_t^{\text{avg}}(1 + g_t^{\text{sell_cost}}) \quad (13)$$

계수 $\{A_b, B_b, C_b, D_b, A_s, B_s, C_s, D_s\}$ 는 환경 상수로 고정되며 값은 §3.3에 명시한다. `sell_cost` 호가만이 평단가를 기준으로 하는 이유는 "원가 회복"을 정책에 명시적으로 노출하기 위함이다.

Reward. 기본형(sym, symmetric)은 1-step PnL 비율이다.

$$r_t^{\text{sym}} = \frac{E_t - E_{t-1}}{C_0}, \quad E_t = c_t + h_t \cdot p_t \quad (14)$$

거래 수수료는 `_execute_buy`와 `_execute_sell`에서 c_t 에 이미 반영되므로 reward에 별도 차감하지 않는다. 본 논문의 4가지 reward 변형은 이 sym을 베이스로 정의되며 §3.4에 상세 기술한다.

3.2 Trading 환경의 동역학

본 절은 매 step의 주문 체결, 사이클 정의, 거래비용 모델을 정리한다.

지정가(limit-order) 체결. 다음 봉(next bar)의 고/저가 (p_{t+1}^H, p_{t+1}^L) 를 바탕으로 4개 호가 각각의 체결 여부를 판정한다.

$$\begin{aligned} p_{t+1}^L &\leq q_t^{\text{buy_hi}} \Rightarrow q_t^{\text{buy_hi}} \text{ 가격에 매수 체결} \\ p_{t+1}^L &\leq q_t^{\text{buy_lo}} \Rightarrow q_t^{\text{buy_lo}} \text{ 가격에 매수 체결} \\ p_{t+1}^H &\geq q_t^{\text{sell_mkt}} \Rightarrow q_t^{\text{sell_mkt}} \text{ 가격에 매도 체결} \\ p_{t+1}^H &\geq q_t^{\text{sell_cost}} \Rightarrow q_t^{\text{sell_cost}} \text{ 가격에 매도 체결} \end{aligned} \quad (15)$$

같은 봉에서 매수와 매도가 동시에 충족되는 경우, 보유분 정리를 우선하여 매도를 먼저 처리한다(자본 회수). 호가 가격이 다음 봉의 범위 내에 들어와도 체결가는 호가 가격 그대로 사용하며 다음 봉 극값으로 체결하지 않는다. 후자는 시뮬레이션에 favorable bias를 주입하므로 이전 버전("next_low/next_high" 체결)을 폐기하고 본 논문에선 지정가 방식만 사용한다.

사이클(cycle) 정의. 사이클은 보유량 θ 인 상태에서 첫 매수가 체결될 때 시작되어 매도로 보유량이 다시 θ 로 복귀할 때 종료된다. 한 사이클 내에서 부분 매수/매도가 여러 번 발생할 수 있으며, 사이클 수익률은 $\text{cycle_pnl} = (c_{\text{end}} - c_{\text{start}})/c_{\text{start}}$ 로 정의한다. 사이클 시작 시 본 사이클에 사용할 슬롯 크기를 결정한다:

$$\text{slot_size}_{\text{cycle}} = \frac{c_{\text{start}}}{n_{\text{splits}}}, \quad \text{order_size} = \frac{\text{slot_size}}{n_{\text{buy_orders}}} \quad (16)$$

본 논문은 $n_{\text{splits}} = 2$, $n_{\text{buy_orders}} = 2$ 를 사용하며 이는 Phase 2 Optuna Trial #34의 best 값이다. `threshold_basis`는 `avg_price`로 고정하여 보유분의 "전량 청산" 판정에 평단가를 사용한다.

거래비용 모델. 거래비용은 Binance maker fee를 기준으로 양측 0.05%로 설정한다. 매수 시 체결 수량은 $\Delta h = \text{order_size} \cdot (1 - f)/q$, 현금 변화는 $\Delta c = -\text{order_size}$ 로 처리되어 fee가 cash에 이미 반영된다. §7.1 (exp033)에서는 추가 슬리피지 $\sigma = 0.02\%$ 를 도입하여 체결가를 $q^{\text{buy}} \cdot (1 + \sigma)$, $q^{\text{sell}} \cdot (1 - \sigma)$ 로 변경한다. 슬리피지는 기본 환경에는 적용하지 않으며 robustness 분석에서만 적용한다.

3.3 ATR 베이스라인

비교 베이스라인은 본 논문의 RL 정책과 환경 + 격자 공식을 공유하되 행동을 규칙 기반(rule-based)으로 결정한다. 구체적으로 ATR 베이스라인은 §3.1의 격자 공식 $g^{\text{buy_hi}}, g^{\text{buy_lo}}, g^{\text{sell_mkt}}, g^{\text{sell_cost}}$ 를 그대로 사용하되, RL action의 자유도를 모두 0으로 고정한 형태이다 ($a_t^{(0)} = a_t^{(1)} = 0$, 따라서 B_b, D_b, B_s, D_s 항은 모두 0이 되어 격자 폭이 시점-독립 상수 A_b, C_b, A_s, C_s 만으로 결정된다). 계수의 값은 Phase 2의 Optuna Trial #34로 결정되었다:

Table 1: ATR 베이스라인의 격자 계수 (Phase 2, Optuna Trial #34).

계수	값	역할	계수	값	역할
A_b	1.665	buy_hi 기본 폭	A_s	0.285	sell_mkt 기본 폭
C_b	6.070	buy_lo 기본 폭	C_s	1.951	sell_cost 기본 폭
B_b	1.748	buy_hi action 감도	B_s	1.950	sell_mkt action 감도
D_b	18.683	buy_lo action 감도	D_s	7.500	sell_cost action 감도

ATR 베이스라인의 Val Sharpe는 슬리피지 없음 기준 1.378이며,¹ 슬리피지 0.02% 적용 시 0.835로 감소한다.

3.4 4가지 Reward 변형

본 논문의 메인 비교 단위인 4가지 reward 변형을 정의한다. 모두 $x_t := r_t^{\text{sym}} = (E_t - E_{t-1})/C_0$ 의 함수로 표현되며, 함수형이 다를 뿐 다른 환경 요소(state, action, ATR 격자, fee)는 모두 동일하다.

(i) Symmetric (sym).

$$r_t^{\text{sym}} = x_t = \frac{E_t - E_{t-1}}{C_0} \quad (17)$$

하이퍼파라미터 없음. 본 논문의 베이스라인.

(ii) Asymmetric (asym).

$$r_t^{\text{asym}} = \begin{cases} x_t & \text{if } x_t \geq 0 \\ \beta \cdot x_t & \text{if } x_t < 0 \end{cases}, \quad \beta > 1 \quad (18)$$

손실 영역에 가중치 β 를 부여하는 위험-회피 효용의 1차 근사이다. Optuna 30 trials $\times$ 200k steps로 val_sharpe를 최대화한 결과 best $\beta = 3.420$ 을 선택했다(탐색 범위 [1.0, 4.0]).

(iii) Differential Sharpe Ratio (dsr). Moody and Saffell [2001]의 정식. EWMA decay rate η 에 대해 1차/2차 모멘트의 온라인 추정값을 다음과 같이 업데이트한다:

$$A_t = A_{t-1} + \eta(x_t - A_{t-1}) \quad (19)$$

$$B_t = B_{t-1} + \eta(x_t^2 - B_{t-1}) \quad (20)$$

$$\Delta A_t = x_t - A_{t-1}, \quad \Delta B_t = x_t^2 - B_{t-1} \quad (21)$$

¹본 논문 초기(2026년 5월 14일) RESEARCH_LOG에는 1.505로 기록되었으나 Phase 16a의 evaluation setup 통일(n_eval_episodes, env config 동기화) 이후 1.378로 재측정되었다. 본 논문 전체에서 1.378을 사용한다.

DSR step reward는 샤프비율 추정값 $\hat{S}_t = A_t / \sqrt{B_t - A_t^2}$ 의 미분(differential) 근사이다:

$$r_t^{\text{dsr}} = \frac{B_{t-1} \Delta A_t - \frac{1}{2} A_{t-1} \Delta B_t}{(B_{t-1} - A_{t-1}^2)^{3/2}} \quad (22)$$

Optuna 30 trials로 best $\eta = 0.0352 \approx 1/28h$ 를 선택했다(탐색 범위 $[1/720, 1/24]$, log-uniform). 이 EWMA 윈도우는 약 1.2일에 해당한다.

(iv) **Prospect-theoretic (pt).** Kahneman and Tversky [1979]과 Tversky and Kahneman [1992]의 효용 함수를 step reward로 직접 사용한다:

$$r_t^{\text{pt}} = \begin{cases} \text{sgn}(x_t) |x_t|^\alpha & \text{if } x_t \geq 0 \\ -\lambda |x_t|^\alpha & \text{if } x_t < 0 \end{cases}, \quad 0 < \alpha \leq 1, \quad \lambda \geq 1 \quad (23)$$

$\alpha < 1$ 은 효용 함수의 오목성(이익에 대한 한계 효용 체감), $\lambda > 1$ 은 손실 회피를 나타낸다. Tversky and Kahneman [1992]의 인간 행동 추정값은 $\alpha = 0.88$, $\lambda = 2.25$ 이나, 본 환경에서 Val Sharpe를 최대화하는 RL 정책에는 best $\alpha = 0.683$, $\lambda = 3.303$ 이 선택되었다(Optuna 30 trials, 탐색 범위 $\alpha \in [0.5, 1.0]$, $\lambda \in [1.0, 4.0]$). 인간 표준보다 더 오목한 효용과 더 강한 손실 회피가 RL 정책에 유리하다는 점은 §6의 메커니즘 결과와 §7.3의 OOS 강건성을 함께 보면 자연스럽게 설명된다.

Optuna 탐색 요약. Asymmetric, DSR, Prospect-theoretic 세 변형 각각 30 trials $\times$ 200k steps의 TPE sampler(Akiba et al. 2019, seed=42, MedianPruner, $n_{\text{startup}} = 5$)로 best 하이퍼파라미터를 찾았다. 총 학습량은 $3 \times 30 \times 200k = 18M$ steps이며 Windows 11 CPU($n_{\text{envs}} = 4$)에서 약 2시간 소요되었다. Symmetric에는 하이퍼파라미터가 없어 Optuna 단계를 건너뛴다.

3.5 PPO 학습 구성과 안정화 패키지

본 논문의 정책 학습은 stable-baselines3 [Raffin et al., 2021]의 PPO [Schulman et al., 2017]를 사용한다. PPO의 표준 hyperparameter ($\gamma = 0.99$, $\lambda_{\text{GAE}} = 0.95$, $\epsilon_{\text{clip}} = 0.2$, v_f coef = 0.5, ∇ clip = 0.5, MLP 정책 [64, 64], batch=256, $n_{\text{epochs}} = 10$, $n_{\text{steps}} = 4096$, $n_{\text{envs}} = 4$)는 stable-baselines3 기본값을 사용하되, 본 환경의 reward 희박성(체결이 발생하지 않은 step에서 reward가 0에 가까움)과 학습 후반의 정책 붕괴 패턴(Phase 2 exp020-022에서 관찰)을 완화하기 위해 다음 학습 안정화 패키지(exp030)를 추가했다:

1. **Learning-rate linear decay:** α_t 가 학습 진행도에 따라 3×10^{-4} 에서 1×10^{-5} 로 선형 감쇠. 학습 후반의 큰 정책 업데이트를 제한하여 best step 이후 붕괴를 완화한다.
2. **Entropy coefficient annealing:** c_{ent} 를 0.01에서 0.001로 선형 감쇠. 초기 충분한 탐색 보장 후 후반에 deterministic 정책으로 수렴 유도.
3. **Target KL divergence early stop:** target_kl = 0.02로 업데이트 단위마다 KL 발산 측정, 임계 초과 시 해당 mini-batch 업데이트 조기 종료. PPO의 근시안적 큰 정책 변화 방지.
4. **Best model checkpoint:** 50k step마다 Val Sharpe 평가 ($n_{\text{eval_episodes}} = 5$), best 시점의 가중치를 별도 저장. 학습 후반 붕괴에 대한 보호.

이 패키지는 exp030(sym reward)에서 Val Sharpe best 1.974, final 1.209의 결과를 보였다(best는 step 550k 시점). 학습 후반 (700k 이후) Sharpe가 final 1.209로 감소하는 붕괴 패턴이 여전히 관찰되어, 본 논문의 모든 평가는 *best* 시점 체크포인트를 사용하며 final 모델은 사용하지 않는다.

3.6 평가 프로토콜

본 논문은 세 가지 평가 환경을 동시에 사용한다. 데이터 분할은 시간 누설을 방지하기 위해 엄격한 시간순으로 구성된다.

Table 2: 데이터 분할.

구분	기간	봉 수(approx.)
Train	2017-08-17 – 2020-12-31	~30,000
Val (single-split)	2021-01-01 – 2023-12-31	~26,000
Test (sealed)	2024-01-01 – 2026-04	~20,000

Val (single-split). §5의 메인 비교 환경. 각 reward 변형 10개 시드 $\times$ 1M steps로 학습한 *best_model*을 Val 전체 구간에 대해 $n_{\text{eval_episodes}} = 5$ 로 평가하여 시드당 Sharpe/MDD/Calmar/거래수/Return을 산출한다.

CPCV 6-fold. §7.2의 다중 분할 환경. López de Prado [2018]의 Combinatorial Purged Cross-Validation을 Train 구간 내부에 6-fold로 적용하여 $\binom{6}{2} = 15$ 개 path(각각 5개월 학습 + 1개월 평가)를 생성한다. Train과 평가 fold 사이에는 1주의 purge 갭을 두어 정보 누설을 방지한다. 4 variant $\times$ 15 path $\times$ 1 seed로 총 60 run을 실행한다.

Test (봉인 해제). §7.3의 OOS 환경. 본 논문의 정직성을 위해 Gort et al. [2022]의 권장에 따라 Test는 exp035 단계(2026-05-16)까지 어떤 탐색 또는 *hyperparameter* 결정 과정에도 노출하지 않고 봉인했다. 봉인 해제 후 100개 RL 모델(4 variant $\times$ 시드/seed-pair 다중)과 ATR 베이스라인, 보유전략(B&H)을 Test 위에서 평가한다.

통계 검정. 모든 페어와이즈 비교에 Cohen’s d 와 부트스트랩 $P(A > B)$ (10^4 resamples)를 적용한다. CPCV 결과의 ATR 대비 단측 t-검정에는 4-way Bonferroni 보정과 Bailey and López de Prado [2014]의 Deflated Sharpe Ratio 검정을 함께 사용한다. 평가의 변동성과 분포 왜곡을 보고하기 위해 Henderson et al. [2018]의 권고를 따라 IQM(Interquartile Mean)과 5% CVaR을 보조 metric으로 보고한다.

4 Phase 1: 대칭 보상 하의 정책 포화

본 절은 본 논문에 앞서 진행된 Phase 1(2026년 4월 작업) 실험 시리즈 exp020–022의 negative finding을 간략히 재인용한다. 이 발견은 본 논문의 reward 정식화 비교(§3.4)를 동기화하는 출발점이다. Phase 1 실험들은 본 논문의 canonical 환경(Env-v4)이 아닌 *Env-v2*(2D ATR 비례 공식, 다음 봉 극값 체결) 위에서 수행되었으므로 절대 Sharpe 수치는 favorable bias artifact를

포함한다. 그러나 본 절의 핵심인 “정책이 상수로 수렴한다”는 정성적 관찰은 환경과 무관하므로 본 논문의 동기로 인용 가능하다.

4.1 정책 포화 현상

Phase 1의 실험 설정은 본 논문 §3와 거의 동일하다: state 7D, action 2D, ATR-비례 격자 공식, symmetric reward $r_t = (E_t - E_{t-1})/C_0$. 차이는 (i) 체결 방식이 다음 봉 극값 기반이라는 점과 (ii) 학습 안정화 패키지 (§3.5)가 아직 도입되기 전이라는 점 두 가지이다.

세 가지 exp 시리즈가 같은 결론을 보였다.

(a) **exp020 (budget_fraction)**. $a_t^{(0)}$ 를 “공격성”에서 “예산 사용 비율”로 재정의했다. 즉, 매 사이클 시작 시 현금 잔고 중 얼마를 본 사이클에 투입할지 RL이 결정한다(0 = 진입 금지, 1 = 전액 투입). 가설은 “하락장에서는 적게 투입, 상승장에는 많이 투입”이었으나 학습된 정책은 모든 레짐에서 $a_t^{(0)} \approx 1.0$ 으로 수렴했다.

(b) **exp021 (entry_gate)**. $a_t^{(0)}$ 를 “사이클 진입 게이트”로 재정의했다(0 = 진입 금지, 1 = 진입 허용). 가설은 “하락장 진입 차단”이었으나 학습 결과는 bear 레짐에서 진입 비율이 99.7%로 사실상 모든 봉에서 게이트가 열렸다.

(c) **exp022 (aggressiveness, 본 논문과 동일한 의미)**. $a_t^{(0)}$ 를 원래의 “공격성”으로 복원한 뒤 1M 스텝 학습. 학습된 deterministic 정책의 행동 통계: 모든 레짐에서 $a_t^{(0)} \approx 0$, $a_t^{(1)} \approx 0$ (중앙값 모두 0.0000, 평균 ≤ 0.001). 가장 결정적인 진단은 정책망의 *raw output*이 $[-9.19, -4.30]$ 로 squash 함수의 saturation 영역에 포화되었다는 사실이다.

4.2 결정적 Ablation: “RL = Fixed [1.0, 0.0]”

행동 통계의 수렴값을 들고 와 RL을 고정 정책으로 교체하는 ablation을 수행했다. aggressiveness 의미 위에서 $a_t = [1.0, 0.0]$ 이 학습된 RL의 행동에 대응한다($a_t^{(0)} \rightarrow 1$ 은 ATR 격자 폭 공식에서 가장 좁은 매수 간격을 의미하며 $a_t^{(1)} \rightarrow 0$ 은 가장 빠른 매도 간격을 의미한다).

Table 3: Phase 1 (Env-v2) Decisive ablation. 절대 Sharpe 수치는 다음 봉 극값 체결의 favorable bias artifact를 포함하지만, RL과 Fixed [1.0, 0.0]의 일치는 환경과 무관한 정성적 결론이다.

정책	Val Sharpe	Test Sharpe
RL exp020 (sym reward, 1M steps)	45.390	42.090
Fixed [1.0, 0.0] (RL 수렴값 그대로 고정)	45.390	41.769
Fixed [1.0, 0.5]	4.116	4.683
Fixed [1.0, 1.0]	1.060	1.843

표 3의 결정적 관찰은 RL과 Fixed [1.0, 0.0]의 Val Sharpe가 소수점 셋째 자리까지 완전히 일치한다는 점이다. 1M 스텝 RL 학습의 결과가 사실상 상수 정책으로 환원되었음을 의미한다. 그 외 Fixed 정책 ([1.0, 0.5], [1.0, 1.0])이 큰 폭으로 열등하다는 점은 “RL이 의미 있게 어떤 점을 골랐다”는 주장을 부분적으로 정당화하지만, 그 “어떤 점”이 시점-독립 상수라는 사실이 핵심이다.

4.3 메커니즘 해석: ATR 공식이 자유도를 흡수한다

정책 포화의 구조적 원인은 격자 공식 자체에 있다. §3.1의 정의를 다시 보면, sell 측 격자 폭은

$$g_t^{\text{sell_mkt}} = \frac{\text{ATR}_{168}(p)}{p_t} \cdot (A_s + B_s \cdot a_t^{(1)}) \quad (24)$$

이며 ATR_{168}/p_t 항이 시장 변동성을 이미 반영한다. 즉, 하락장($\text{ATR} \uparrow$)에는 격자 폭이 자동 확대되어 보수적 포지션이 자동 달성되고, 상승장($\text{ATR} \downarrow$)에는 격자 폭이 자동 축소되어 공격적 포지션이 자동 달성된다. RL에게 남은 역할은 “ATR이 결정한 폭을 어떻게 추가 조정할까?” 인데, symmetric reward 하에서는 사이클 수 극대화 $\rightarrow$ 복리 누적 극대화가 유일한 최적화 방향이고, 그 결과 매수 격자는 가장 좁게($a_t^{(0)} \rightarrow 1$), 매도 격자도 가장 좁게($a_t^{(1)} \rightarrow 0$) 가 단일 최적해가 된다. 상태 의존적 행동을 학습할 인센티브가 사라진다.

4.4 본 논문의 동기

Phase 1 negative finding의 표면적 결론은 “BTC 그리드 트레이딩에서 RL은 의미 없다”로 보였으나, 본 논문은 이 결론이 *symmetric reward*라는 특정 가정에 조건적이라는 가설을 채택했다. 즉:

대칭 $\text{reward} + \text{ATR}$ 비례 공식의 조합이 RL 자유도를 흡수한다면, reward 를 비대칭으로 정식화(*asymmetric, prospect-theoretic*) 하거나 경로 의존적 으로 정식화(*DSR*의 *sliding-window memory*) 하면 RL이 추가 가치를 가질 수 있는가?

이 가설은 본 논문의 핵심 비교 (§3.4, §5)로 정식화된다. 또한 본 논문의 canonical 환경(Env-v4, 지정가 체결 + 학습 안정화 패키지)에서 symmetric reward만으로도 RL이 ATR 베이스라인을 초과함을 추가로 확인할 것이다(§5 결과에서 Val Sharpe sym = 1.87 > ATR 1.378). 즉, Phase 1의 “RL = Fixed”라는 강한 negative는 체결가 *favorable bias*와 학습 안정성 부족이 동시에 작용한 특정 조건의 결과이며, 환경이 정상화되고 학습이 안정화된 본 논문 조건에서는 reward 형식 자체가 RL의 가치-부가 채널의 주된 결정 요인이 된다는 것이 본 논문의 메시지이다.

5 Pareto 프론티어와 시나리오 D

본 절은 본 논문의 첫 메인 발견인 4 reward 변형의 Pareto-유사 프론티어 구조를 제시한다. §3.4에서 정의한 네 가지 reward 형식을 canonical 환경(Env-v4) 위에서 10 시드 $\times$ 100만 스텝으로 학습한 결과 40개 정책의 risk-return 좌표가 단일 winner가 아닌 두 클러스터로 분리되며 Sharpe-MDD 평면에서 trade-off frontier를 형성함을 보인다. 사전에 등록한 시나리오 A/B/C 어디에도 해당하지 않는 사후 시나리오 “D”로 정의되며, 본 논문의 multi-dimensional 정직한 정량화의 출발점이다.

5.1 실험 설정

§3.4의 4 변형을 각각 10 시드(seed 42–51)로 학습한다. PPO 설정과 학습 안정화 패키지는 §3.5와 동일하며, asym/dsr/pt의 하이퍼파라미터는 §3.4의 Optuna best를 사용했다 ($\beta = 3.42$, $\eta = 0.0352$, $\alpha = 0.683$, $\lambda = 3.303$). sym은 하이퍼파라미터가 없다. 총 학습량 $4 \times 10 \times 1\text{M} = 40\text{M}$ 스텝으로 Windows 11 CPU($n_{\text{envs}} = 4$)에서 약 3시간 44분 소요되었다.

평가는 §3.6의 Val(2021–2023) 단일 분할 위에서 각 시드의 best_checkpoint를 사용하며 metric은 best Val Sharpe, final Val Sharpe, MDD, Calmar, 거래수, 누적 수익률이다. final Val Sharpe는 1M 스텝 종료 시점의 정책 성능으로, best와의 차이는 학습 후반 정책 안정성의 척도이다.

5.2 Per-variant 결과: 4 metric 1위가 모두 다르다

표 4는 10 시드 평균 $\pm$ 표준편차로 측정한 6 metric의 variant 별 결과이다.

Table 4: exp032b 결과. 10 시드 $\times$ 1M 스텝 학습 후 Val 평가. ATR 베이스라인은 단일 결정적 정책이므로 std 없음. 굵게는 metric 별 1위.

Variant	Best Sharpe	Final Sharpe	MDD (%)	Calmar	Trades	Return (%)
sym	1.871 $\pm$ 0.22	1.015 $\pm$ 0.43	3.27 $\pm$ 0.82	0.60	120	6.60
dsr	1.809 $\pm$ 0.21	1.204 $\pm$ 0.41	4.33 $\pm$ 1.70	0.47	117	7.40
asym	1.681 $\pm$ 0.10	1.101 $\pm$ 0.27	2.28 $\pm$ 0.31	0.755	96	5.23
pt	1.667 $\pm$ 0.09	1.082 $\pm$ 0.18	2.31 $\pm$ 0.29	0.735	85	4.88
ATR baseline	1.378	—	9.83	0.153	2,121	35.80

두 가지 핵심 관찰:

(i) 4 variant 모두 ATR 베이스라인을 초과한다. Best Val Sharpe 기준으로 ATR(1.378) 대비 +21%(sym)에서 +21%(pt) 구간이며 모두 통계적으로 유의하다(per-variant bootstrap 95% CI 하한이 1.5 초과). §4의 “RL = Fixed [1.0, 0.0]”와는 정성적으로 다른 결과이며, 환경 정상화(지정가 체결)와 학습 안정화 패키지(§3.5)의 효과로 해석된다. sym이 ATR을 명확히 초과한다는 사실 자체가 가설 H1 (sym RL $\approx$ ATR)을 부정한다.

(ii) 4 metric 1위가 서로 다르다. sym은 best Sharpe 1위, dsr은 final Sharpe와 누적 수익률 1위, asym은 MDD와 Calmar 1위, pt는 모든 metric에서 asym와 미세한 차이로 2위이다. 단일 winner가 없으며 metric 선택에 따라 “best variant”가 달라지는 multi-dimensional trade-off 구조이다. 가설 H2 strong (asym/dsr/pt > sym)이 부분 부정된다.

5.3 Pareto 프론티어 시각화

그림 1은 40개 정책의 (Sharpe, MDD) 좌표를 reward variant 별로 색상 분리하여 표시한 산점도이다. 두 가지가 두드러진다.

첫째, 같은 variant 내 10 시드의 점들은 좁은 영역에 응집되어 asym과 pt의 표준편차는 std $\approx$ 0.10(표준편차/평균 $\approx$ 6%)로 매우 작다. 이는 두 conservative variant의 정책이 시드에 강건함을 의미한다. sym과 dsr은 std $\approx$ 0.22로 약간 더 분산되어 있다.

둘째, sym과 dsr의 점 집합은 서로 대부분 겹치며, asym과 pt의 점 집합 역시 서로 대부분 겹친다. 그러나 {sym, dsr}와 {asym, pt}는 거의 겹치지 않는다. 이 점-수준의 시각적 분리가 다음 절의 통계적 클러스터 분석 결과로 정량화된다.

5.4 두 클러스터의 통계적 분리

페어와이즈 Cohen’s d (best Val Sharpe)와 부트스트랩 $P(A > B)$ 를 10^4 resample로 산출하여 표 5와 표 6에 정리한다.




Figure 1: 40개 정책(4 variant $\times$ 10 시드)의 Sharpe–MDD 평면 산점도. 가로축은 best Val Sharpe($\uparrow$ 좋음), 세로축은 MDD($\downarrow$ 좋음). sym/dsr이 높은 Sharpe + 높은 MDD의 *aggressive* 영역에 모이고, asym/pt는 중간 Sharpe + 낮은 MDD의 *conservative* 영역에 모인다. ATR 베이스라인은 같은 평면의 (1.378, 9.83) 위치이며 모든 RL 정책이 Pareto-dominate한다.

Table 5: Pairwise Cohen’s d (best Sharpe, row – col). $|d| < 0.3$ 은 “작은 차이”, $|d| > 0.8$ 은 “큰 차이”로 해석된다. 그룹 내 cell이 $|d| < 0.3$, 그룹 간 cell이 $|d| > 0.8$ 임을 굵게 강조했다.

	sym	asym	dsr	pt
sym	—	+1.10	+0.29	+1.19
asym	−1.10	—	−0.79	+0.15
dsr	−0.29	+0.79	—	+0.89
pt	−1.19	−0.15	−0.89	—

표 5의 패턴이 결정적이다.

- **그룹 내** (within-cluster): sym vs dsr $|d| = 0.29$, asym vs pt $|d| = 0.15$. 둘 다 “작은 차이” 범위.
- **그룹 간** (across-cluster): sym vs asym $|d| = 1.10$, sym vs pt $|d| = 1.19$, dsr vs asym $|d| = 0.79$, dsr vs pt $|d| = 0.89$. 네 페어 모두 $|d| > 0.79$.

즉 4개 변형은 다음 두 클러스터로 통계적으로 분리된다:

$$\underbrace{\{\text{sym}, \text{dsr}\}}_{\text{aggressive}} \quad \text{vs.} \quad \underbrace{\{\text{asym}, \text{pt}\}}_{\text{conservative}}$$

5.5 정책 거리: 행동 수준의 클러스터 확인

위 통계는 Sharpe 분포 수준의 분리만 보여준다. 클러스터가 정책의 행동 수준에서도 존재하는지 확인하기 위해 40개 best_model을 Val 전 구간에 대해 deterministic 구동하여 각 시드의

Table 6: Pairwise $P(\text{row} > \text{col})$ (best Sharpe, 10^4 bootstrap resamples). 1에 가까울수록 row가 col을 압도, 0.5는 동등.

	sym	asym	dsr	pt
sym	—	0.998	0.746	0.999
asym	0.003	—	0.031	0.634
dsr	0.254	0.968	—	0.984
pt	0.001	0.363	0.018	—

action 시계열을 수집한 뒤, variant 쌍 사이의 평균 L_2 action 거리를 계산했다 (variant 당 10 시드 평균).




Figure 2: 4 variant 간 정책 거리 행렬. cell의 값은 두 variant 정책의 평균 L_2 action 거리. 대각선은 0. 색은 진할수록 거리가 가깝다.

그림 2의 값 (대각선 제외):

- **그룹 내:** sym vs dsr = 0.123, asym vs pt = 0.134. 평균 = 0.129.
- **그룹 간:** sym vs asym = 0.209, sym vs pt = 0.326, dsr vs asym = 0.256, dsr vs pt = 0.353. 평균 = 0.286.

그룹 간 / 그룹 내 비율 = $0.286/0.129 = 2.22\times$. 즉 같은 클러스터의 정책끼리는 다른 클러스터의 정책보다 2.22배 더 행동 자체가 유사하다. Sharpe metric 수준의 클러스터가 정책 행동 수준의 클러스터로 일관 확인된다.

5.6 시나리오 D 확정과 가설 점검

본 연구 시작 단계에서 검증 가능한 결과를 ex-post rationalization 없이 평가하기 위해 사전 시나리오 분기를 등록했다.

- **시나리오 A (낙관):** asym/dsr/pt가 sym과 ATR 모두를 Cohen's $d \geq 0.5$ 로 유의하게 초과. "Reward design이 RL 알파의 핵심 채널" thesis 직접 지지.
- **시나리오 B (중립):** variant 간 차이는 있으나 ATR에 못 미침. "ATR 비례 공식이 강한 변동성 흡수력 보유" — negative finding 확장.
- **시나리오 C (비관):** variant 간 차이 미미. "Reward 형식 변형이 의미 없음" — Phase 1 발견의 강화.

본 절의 결과는 사전 분기 어디에도 정확히 들어맞지 않는다. 4 variant 모두 ATR을 초과하지만 (B 부정), 단일 winner는 없고(A의 asym/dsr/pt 1위 가설 부정), 그렇다고 variant 간 차이가 없는 것도 아니다(C 부정, 두 클러스터 통계적 분리). 따라서 사후 분기로 **시나리오 D (Pareto 프론티어 / 다차원 trade-off)**를 정의한다:

4 reward 변형은 단일 metric의 alpha source가 아니라 **risk profile 차원의 trade-off**로 분리되며, Sharpe-MDD 평면에서 Pareto-유사 frontier를 형성한다. 두 클러스터 ($\{sym, dsr\}$ 와 $\{asym, pt\}$)는 Sharpe 분포 수준(*within-cluster* $|d| < 0.30$, *across-cluster* $|d| > 0.79$)과 정책 행동 수준(거리 비율 2.22배) 모두에서 일관 확인된다.

가설 H1-H4의 본 절 시점 결론:

- **H1 (sym RL $\approx$ ATR): 부정.** sym best Sharpe 1.871은 ATR 1.378을 $|d| > 0.6$ 로 초과 (per-variant t-test $p < 10^{-3}$).
- **H2 weak (asym/dsr/pt $>$ ATR): 지지.** 4 variant 모두 ATR 초과, conservative 클러스터는 추가로 MDD/Calmar 우위.
- **H2 strong (asym/dsr/pt $>$ sym): 부분 부정.** dsr은 sym과 유사(within-cluster), asym/pt는 sym 보다 낮은 Sharpe.
- **H3 (selective entry $\rightarrow$ conservative): 지지.** conservative 클러스터의 거래수는 sym 대비 약 75%(asym 96, pt 85 vs sym 120). 정확한 메커니즘 정량화는 §6에서 다룬다.

5.7 exp027_rl 사전 증거의 환경 의존성

본 논문의 동기에는 Phase 2 후기(2026년 4월)에 관찰된 asym reward ($\beta = 2.0$)의 강한 우위가 있었다. 당시 Env-v3(4D 절대 gap, 지정가 체결)에서 asym RL은 Test Sharpe 1.955를 기록하여 ATR Test 0.935를 +109% 초과했다. 본 논문 환경(Env-v4, 2D ATR 비례, $\beta = 3.42$ 로 Optuna 재튜닝)에서는 asym Val Sharpe 1.681로 sym 1.871보다 낮다. 즉 사전 증거의 강한 asym 우위는 재현되지 않았다. 이는 reward variant 효과보다 환경 설정(action 차원 수, 격자 공식 형식)의 효과가 큼을 시사한다. 본 논문은 §8에서 이 환경 의존성을 정직하게 인정한다. 본 절의 메인 결론(시나리오 D, Pareto 프론티어)은 환경 의존성 인정과 무관하게 canonical Env-v4 위에서 통계적으로 확립된다.

6 메커니즘 정량화

[TBD: 추후 작성. exp032c 결과: Policy distance 행렬, behavior per regime, counterfactual action map, action distribution. 인과 사슬: reward 형식 $\rightarrow$ 거래 빈도 $\rightarrow$ 클러스터.]

7 강건성 분석

7.1 Slippage 강건성

[TBD: 추후 작성. *exp033: 4 variants $\times$ 10 seeds with slippage 0.02%. Cluster preservation ratio $2.19\times$. ATR-with-slippage fair 비교 결과 (Phase 16a).*]

7.2 CPCV 다중 split 평가

[TBD: 추후 작성. *exp034: 6-fold CPCV 15 paths. DSR $p < 0.001$ (Bonferroni 4-way 보정), *dss* variant reversal 1위 (1.413 , 5% CVaR 0.890), Cluster ratio $3.55\times$.]*

7.3 분포 외 평가와 Prospect Theory의 강건성

[TBD: 추후 작성. 본 논문의 핵심 챕터. *exp035: 100 RL models + ATR baseline + Buy-and-Hold Test. *pt*의 Test 1위 (두 소스 $p < 0.002$), *dss*의 Test 꼴찌. Phase 16d mechanism: holding 시간 분포 (DSR 7-day max vs. *pt* 6h max). *pt*의 분포 외 강건성의 인과 사슬.*]

8 논의

[TBD: 추후 작성. 서브 섹션: §8.1 Val-Test 분포 이동의 정량 ($KS\ p < 10^{-10}$, -27% variance), §8.2 *exp027_rl* 사전 증거 (*Env-v3 asym 1.955*)의 환경 의존성 정직 인정, §8.3 단일 metric winner의 한계, §8.4 한계: BTC 단일 자산, Test 1 regime, single slippage level.]

9 결론

[TBD: 추후 작성. 4개 메인 메시지: (1) Pareto 프론티어 trade-off, (2) 평가 환경별 winner reversal, (3) Prospect Theory의 OOS 강건성, (4) In-sample 우위 $\neq$ OOS 강건성. Future work: multi-asset, regime, DR, meta-RL.]

References

- Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 2623–2631, 2019.
- Marco Avellaneda and Sasha Stoikov. High-frequency trading in a limit order book. *Quantitative Finance*, 8(3):217–224, 2008. doi: 10.1080/14697680701381228.
- David H. Bailey and Marcos López de Prado. The deflated sharpe ratio: Correcting for selection bias, backtest overfitting, and non-normality. *Journal of Portfolio Management*, 40(5):94–107, 2014.
- Charan Bandaruwalli. Risk-aware deep reinforcement learning for cryptocurrency and equity trading. *arXiv preprint*, 2025.

- Bryan Gort, Xiao Chen, Matthew Tong, Shaojie Xu, and Xingjian Li. Deep reinforcement learning for cryptocurrency trading: Practical approach to address backtest overfitting. *arXiv preprint arXiv:2209.05559*, 2022.
- Peter Henderson, Riashat Islam, Philip Bachman, Joelle Pineau, Doina Precup, and David Meger. Deep reinforcement learning that matters. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 32, 2018.
- Daniel Kahneman and Amos Tversky. Prospect theory: An analysis of decision under risk. *Econometrica*, 47(2):263–291, 1979. doi: 10.2307/1914185.
- Hao Yuan Timothy Liu. Reinforcement learning trading strategies: A literature review. *arXiv preprint arXiv:2502.06551*, 2025.
- Yang Liu, Qi Liu, Hongke Zhao, Zhenya Pan, and Chuanren Liu. Adaptive quantitative trading: An imitative deep reinforcement learning approach. 34(02):2128–2135, 2020. Referenced as Liu et al. (2021) for the PPO+LSTM Bitcoin trading variant.
- Marcos López de Prado. *Advances in Financial Machine Learning*. Wiley, 2018. Combinatorial Purged Cross-Validation (CPCV), Chapter 7.
- John Moody and Matthew Saffell. Learning to trade via direct reinforcement. *IEEE Transactions on Neural Networks*, 12(4):875–889, 2001. doi: 10.1109/72.935097. Differential Sharpe Ratio (DSR) formulation.
- Andrew Y. Ng, Daishi Harada, and Stuart Russell. Policy invariance under reward transformations: Theory and application to reward shaping. In *Proceedings of the 16th International Conference on Machine Learning (ICML)*, pages 278–287, 1999.
- Minh Pham, Anh Le, and Binh Nguyen. Dqn-based bitcoin technical trading strategy selection. *arXiv preprint*, 2025.
- Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268):1–8, 2021.
- John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- Siyu Sun, Rundong Wang, and Bo An. Reinforcement learning for quantitative trading. *ACM Transactions on Intelligent Systems and Technology*, 14(3):1–29, 2023. doi: 10.1145/3582560.
- Amos Tversky and Daniel Kahneman. Advances in prospect theory: Cumulative representation of uncertainty. *Journal of Risk and Uncertainty*, 5(4):297–323, 1992. $\alpha = 0.88$, $\lambda = 2.25$ standard parameters.
- J. Welles Wilder. New concepts in technical trading systems. 1978.
- Hafiz Muhammad Athar Yasin and Asim Anwar Gill. Reinforcement learning framework for quantitative trading. *International Journal of Computer Applications*, 186(8):1–9, 2024.

Zihao Zhang, Stefan Zohren, and Stephen Roberts. Deep reinforcement learning for trading.
The Journal of Financial Data Science, 2(2):25–40, 2020.