

BTC 강화학습 그리드 트레이딩에서 Reward 함수 설계의 영향:

Pareto 프론티어, Winner Reversal, 그리고 Prospect Theory의 분포 외 강건성

이찬희 (Lee Chanhee)

컴퓨터공학부

서울과학기술대학교

happilyfly@seoultech.ac.kr

2026년 6월

Abstract

본 논문은 BTC/USDT 1시간봉 시장에서 가격 방향 예측 없이 ATR(Average True Range) 비레 지정가 그리드를 결정하는 PPO 기반 강화학습 정책에 대해 *reward* 함수 설계가 정책의 행동 패턴과 일반화 성능에 미치는 영향을 정량 검증한다. 4가지 reward 변형 — 대칭 보상 (sym), 비대칭 보상 (asym, $\beta = 3.42$), 미분 샤프 비율 (dsr, $\eta = 1/28h$), 프로스펙트 이론 보상 (pt, $\alpha = 0.68, \lambda = 3.30$) — 을 동일 환경에서 각각 10 시드 $\times$ 100만 스텝 학습 후, (i) 단일 분할 검증 (Val 2021–2023), (ii) 6중 CPCV(Combinatorial Purged CV) 15-path 평가, (iii) 봉인 해제된 테스트 셋(Test 2024–2026) 분포 외 평가의 세 환경에서 비교한다.

주요 발견: (1) Val에서 4개 변형이 ATR 기반 베이스라인(Val Sharpe ≈ 1.38 –1.51)을 모두 +11 ~ 24% 초과하나 단일 winner는 없으며, 두 클러스터 {sym, dsr}(공격적) vs {asym, pt}(보수적)로 통계적으로 분리된다(그룹 내 $|d| < 0.3$, 그룹 간 $|d| > 0.8$). (2) Reward 형식이 정책의 거래 빈도와 holding 시간을 직접 결정하며 (정책 거리 비율 2.22배), dsr의 hold rate가 다른 변형의 2–6배인 것이 sliding-window reward 자체의 메모리 구조 결과임을 정량 확인한다. (3) 평가 환경별로 winner가 reversal: Val의 sym(1.87) $\rightarrow$ CPCV의 dsr(1.41, $p < 0.001$) $\rightarrow$ Test의 pt(0.34–0.37, 두 소스 일관 $p < 0.002$). (4) pt의 분포 외 강건성 메커니즘: $\lambda = 3.30$ 손실 회피와 $\alpha = 0.68$ 오목한 효용함수가 정책의 매수 후 평균 1.4시간(최대 6시간) 빠른 청산을 학습시켜 미관측 강세장(BTC \$42K $\rightarrow$ \$76K)의 매도 타이밍 위험을 회피한다. 반면 dsr은 평균 4.58시간(최대 169시간 = 7일) holding을 학습시켜 동일 환경에서 최악 성능 기록. (5) Val–Test 분포 차이가 통계적으로 매우 유의(KS $p < 10^{-10}$, 변동성 +27%) 하며, 모든 정책의 Val/Test 행동은 거의 동일($\Delta \text{action} \leq 5\%$)이므로 OOS 성능 차이는 정책이 아닌 시장 분포 이동이 직접 원인이다.

본 연구의 학술적 기여는 reward 설계의 효과가 단일 Sharpe metric의 “alpha source”가 아니라 *risk profile* 차원의 *trade-off* + 평가 환경별 *winner reversal*로 나타남을 정량 보이는 것이며, Kahneman과 Tversky(1979)의 prospect theory가 강화학습 정책에 부여하는 분포 외 안전성을 첫 정량 확인한 것이다. 코드와 데이터: <https://github.com/cosmicpotato2047/capstone-rl-trading>.

키워드: 강화학습, 그리드 트레이딩, PPO, Reward Design, Prospect Theory, Differential Sharpe Ratio, CPCV, 분포 외 일반화, 암호화폐

Abstract (English)

We quantitatively study the effect of *reward function design* on PPO-based RL policies for ATR-proportional grid trading on the BTC/USDT 1-hour market. Four reward variants—symmetric (**sym**), asymmetric ($\beta = 3.42$, **asym**), Differential Sharpe Ratio ($\eta = 1/28$ h, **dsr**), and prospect-theoretic ($\alpha = 0.68$, $\lambda = 3.30$, **pt**)—are each trained with 10 seeds $\times$ 1M steps and evaluated on three environments: (i) single-split validation (Val 2021–2023), (ii) 6-fold CPCV 15 paths, and (iii) the unsealed out-of-sample Test (2024–2026, BTC \$42K $\rightarrow$ \$76K).

Key findings: (1) All four variants exceed the ATR baseline by +11–24% on Val, but partition into two clusters {**sym**, **dsr**} (aggressive) vs. {**asym**, **pt**} (conservative); within-cluster $|d| < 0.3$ vs. across-cluster $|d| > 0.8$. (2) Mechanism: reward asymmetry directly determines trade frequency and holding time (policy distance ratio 2.22 $\times$), and the sliding-window memory of DSR results in 2–6 $\times$ higher hold rate. (3) Winner reverses across evaluation environments: Val=**sym**(1.87) $\rightarrow$ CPCV=**dsr**(1.41, $p < 0.001$) $\rightarrow$ Test=**pt**(0.34–0.37, consistent across two sources, $p < 0.002$). (4) Mechanism for **pt**'s OOS robustness: short holding (mean 1.4 h, max 6 h) avoids sell-side timing risk in the unseen bull market. In contrast, **dsr** learns long holding (mean 4.58 h, max 169 h = 7 days) and records the worst OOS performance, showing that the same reward formulation drives both in-sample advantage and OOS failure as two sides of the same coin. (5) Val–Test distribution shift is statistically significant (KS $p < 10^{-10}$, –27% variance), while policy actions remain nearly invariant ($\Delta \leq 5\%$) between Val and Test, indicating the regime shift, not the policy, drives OOS differences. Our main contribution is the quantitative demonstration that reward design exerts its effect through the trade-off dimension rather than a single Sharpe “alpha source,” and provides the first quantitative evidence that Kahneman-Tversky prospect theory confers OOS safety on RL trading policies.

Contents

1	서론	4
1.1	동기와 연구 질문	4
1.2	기여 사항	4
1.3	본 논문 구성	5
2	관련 연구	5
2.1	시장 구성과 그리드 트레이딩	5
2.2	강화학습 기반 트레이딩	5
2.3	Reward 설계 이론	6
2.4	평가 방법론	7
3	방법론	7
4	Phase 1: 대칭 보상 하의 정책 포화	8
5	Pareto 프론티어와 시나리오 D	8
6	메커니즘 정량화	8
7	강건성 분석	8
7.1	Slippage 강건성	8
7.2	CPCV 다중 split 평가	8
7.3	분포 외 평가와 Prospect Theory의 강건성	8
8	논의	8
9	결론	8

1 서론

BTC 등 암호화폐 시장의 시간봉 가격 변동은 장기 추세와 무관한 빈번한 미세 진동 (micro-oscillation)이 본질적 특성으로, 이 변동성 자체를 수익원으로 삼는 그리드 트레이딩(grid trading)은 시장 조성(market making) [Avellaneda and Stoikov, 2008]의 단순화된 변형이다. 고정된 가격 격자 위에 매수/매도 주문을 정기적으로 배치하는 단순한 규칙 기반 전략부터, ATR(Average True Range) [Wilder, 1978] 비례로 격자 폭을 동적 조정하는 변동성 적응형 변형까지 다양한 구현이 존재한다. 본 연구는 후자, 즉 ATR 비례 그리드 트레이딩의 격자 폭과 체결 가격을 강화학습 정책으로 결정하는 시스템을 다룬다.

1.1 동기와 연구 질문

본 시스템의 초기 가설(2026년 1-3월 작업)은 “PPO 강화학습이 동적 변동성 적응을 학습하여 고정 그리드 베이스라인을 초과한다”였다. 그러나 사후 분석 결과 학습된 정책이 사실상 상수 액션 [1.0, 0.0]으로 수렴함이 확인되었고 (§4 상세), Bayesian으로 최적화된 ATR 계수 자체가 성능의 주요 원동력임이 드러났다. 이 negative finding은 대칭 보상(symmetric reward) + ATR 비례 공식의 조합이 RL 정책의 자유도를 본질적으로 흡수한다는 가설로 이어졌고, 본 논문의 새 연구 질문을 동기화한다:

BTC 그리드 트레이딩에서 reward 함수의 설계가 RL 정책의 행동 패턴과 일반화 성능에 어떤 영향을 미치는가? 특히, 손실 비대칭(asymmetric, prospect-theoretic) 또는 위험 조정 수익(DSR) 형태의 reward 정식화가 단일 metric 우위 또는 분포 외(out-of-sample) 강건성 측면에서 의미 있는 차이를 만드는가?

1.2 기여 사항

본 논문의 학술적 기여는 다음 네 가지이다.

1. **Reward 변형의 통계적으로 엄밀한 비교 프레임워크**: 4가지 reward 함수(sym, asym, dsr, pt)를 동일 환경에서 10 시드 × 100만 스텝으로 학습하고, Cohen’s d , 부트스트랩 $P(A > B)$, IQM, 5% CVaR을 사용하여 페어와이즈 통계 검정을 수행한다.
2. **시나리오 D — Pareto 프론티어 발견**: 단순 “X reward가 best”의 단일 winner 결론 대신, 4 변형이 {sym, dsr}와 {asym, pt}의 두 클러스터로 통계적으로 분리되어 Sharpe-MDD 평면에서 Pareto-유사 프론티어를 형성함을 보이며 (§5), 이는 사전에 설정한 시나리오 분기(낙관 A/중립 B/비관 C) 어디에도 해당하지 않는 새로운 결과 형태이다.
3. **Reward → 행동 → 결과의 인과 사슬 정량**: 변형 간 정책 행동의 차이를 1.04M step trajectory 위에서 정책 거리 행렬(within-cluster 0.129 vs. across-cluster 0.286), regime별 거래/holding 통계, 행동 분포 비교로 정량화하여 “reward 형식의 손실 비대칭 → 거래 빈도 감소 → 보수적 클러스터”의 메커니즘을 확인한다 (§6).
4. **평가 환경별 winner reversal과 Prospect Theory의 OOS 강건성**: Single-split Val(sym 1위) → CPCV multi-split(dsr 1위) → 봉인 해제된 Test(pt 1위, 두 소스 일관 $p < 0.002$)의 세 환경에서 winner가 완전 reversal한다 (§7). pt의 OOS 강건성 메커니즘은 prospect theory의 손실 회피 $\lambda = 3.30$ 과 오목 효용 $\alpha = 0.68$ 이 정책의 holding을 매우 짧게(평균 1.4시간) 학습시켜 미관측 강세장의 매도 타이밍 위험을 회피하는 결과임을 trajectory 분석으로 입증한다.

이는 Kahneman과 Tversky(1979)의 이론이 강화학습 정책에 부여하는 분포 외 안전성의 첫 정량 확인이다.

1.3 본 논문 구성

§2는 RL 트레이딩, reward 설계 이론, 평가 방법론의 선행 연구를 정리한다. §3는 환경 설계(MDP, ATR 공식, 4 reward 변형)와 PPO 학습 설정을 기술한다. §4는 본 연구의 동기인 Phase 1 negative finding("RL = Fixed [1.0, 0.0]")을 간략 재인용한다. §5는 Val에서의 두 클러스터 발견(시나리오 D)을, §6은 메커니즘 정량을 다룬다. §7은 slippage 견고성(§7.1), CPCV 다중 split(§7.2), 그리고 본 논문의 핵심인 Test OOS와 prospect theory의 강건성 메커니즘(§7.3)을 다룬다. §8은 분포 이동의 정량과 한계를 논의하며, §9에서 마무리한다.

2 관련 연구

본 연구는 (i) 시장 조성과 그리드 트레이딩, (ii) 강화학습 기반 트레이딩, (iii) reward 설계 이론, (iv) 트레이딩 정책의 평가 방법론의 네 분야 교차점에 위치한다. 이 절은 각 분야의 핵심 선행 연구를 정리하고, 본 논문이 차지하는 좌표를 명시한다.

2.1 시장 조성과 그리드 트레이딩

그리드 트레이딩의 학술적 조상은 Avellaneda and Stoikov [2008]의 시장 조성 (market making) 모델이다. 이 연구는 위험 회피적 시장 조성자가 재고 위험(inventory risk)에 직면할 때, 중심 가격(mid-price)을 중심으로 매수/매도 호가를 대칭적이지 않게 배치하는 최적 정책의 폐형 해(closed-form solution)를 유도한다. 핵심 통찰은 (a) 호가의 폭(spread)이 변동성과 시간 잔여량의 함수로 결정되며, (b) 재고 편향(inventory skew)이 호가 중심을 비대칭적으로 이동시킨다는 것이다. 그리드 트레이딩은 이 모델의 단순화된 실용 변형으로, 고정 간격 격자에 주문을 미리 배치하여 미세 변동성을 수익화한다.

격자 폭을 시장 변동성에 적응시키는 표준 방법은 Wilder [1978]의 ATR(Average True Range, 14일 이동평균 윈도우 표준)을 사용하는 것이다. ATR은 실제 변동 폭(true range)의 평활 평균으로 변동성 클러스터링(volatility clustering) 구간에서 격자 폭을 자동 확장하는 단순하고도 견고한 규칙을 제공한다. ATR 비례 그리드 ($\Delta = c \cdot \text{ATR}$, c = 비례 계수)는 실무에서 널리 사용되며, 본 연구의 베이스라인이기도 하다.

이 분야의 기존 학술 연구는 대부분 규칙 기반(rule-based) 정책의 분석에 머물러 있으며, 격자 폭 결정을 데이터로부터 학습하는 시도는 제한적이다. 본 논문은 ATR 비례 공식의 비례 계수와 격자 분할 수를 강화학습 정책으로 동적 결정하는 구조를 채택하면서도, 동시에 reward 함수 설계가 학습된 정책의 행동에 어떤 영향을 미치는지 정량적으로 분석한다는 점에서 차별성을 가진다.

2.2 강화학습 기반 트레이딩

암호화폐 시장에 대한 DRL 트레이딩의 표준 베이스라인은 Zhang et al. [2020]이 제시한 PPO/A2C/DQN 비교 프레임워크이다. 이 연구는 가격 시계열을 입력으로 직접 받는 PPO 정책이 단순 buy-and-hold(B&H)와 무빙 평균 교차 전략을 일관적으로 초과하는 결과를 보였다. Sun et al. [2023]의 ACM Transactions 서베이와 Liu [2025]의 최근 리뷰는 이 분야의 두 가지 미해결

과제로 (a) 정책 행동의 해석 가능성, (b) 시장 레짐 간 일반화를 지적한다. 본 논문은 이 두 과제를 직접 다룬다: §6에서 reward 형식에서 행동 차이로 가는 인과 사슬을 정량화하며, §7에서 단일 분할 검증으로 잡히지 않는 분포 외(OOS) 일반화 현상을 보고한다.

직접 선행 연구는 네 편이다. Liu et al. [2020]은 LSTM 가격 예측의 출력을 PPO 정책의 state로 입력하는 2단계 구조를 제안했다. 이 접근의 한계는 예측 오류가 정책 결정에 그대로 전파된다는 점이며, 본 논문은 가격 예측 단계를 완전 제거한 변동성 적응형 그리드 구조로 이 한계를 우회한다. Yasin and Gill [2024]은 DQN/PPO/A2C 세 알고리즘과 20개 기술지표를 비교하나, action 공간이 이산 buy/sell이고 holding 행동이 없는 한계가 있다. 본 논문은 연속 2차원 action(공격성과 이익 목표)을 채택해 그리드의 미세 조정을 가능하게 한다. Pham et al. [2025]은 사전 정의된 5개 전략 중 하나를 DQN으로 선택하는 메타-전략 구조이나, 전략 자체는 학습되지 않는다. Bandarupalli [2025]는 PPO에 변동성 패널티와 거래 비용 항을 추가하나, 단일 reward 변형의 hyperparameter 조정 수준에 머물러 본 논문이 다루는 reward 형식 자체의 비교는 포함하지 않는다.

특히 중요한 선행 연구는 Gort et al. [2022]이다. 이 논문은 암호화폐 DRL 트레이딩에서 단일 train/test 분할의 결과가 OOS 일반화를 보장하지 않는다는 실증을 제시하며, CPCV(Combinatorial Purged Cross-Validation)와 DSR(Deflated Sharpe Ratio)을 권장한다. 본 논문은 Gort et al.의 평가 권장사항을 채택하여 Val (2021–2023) / CPCV 6-fold (Train 분할 내부) / Test (2024–봉인 해제) 세 환경을 동시에 사용한다. 본 논문의 winner reversal 발견(Val sym → CPCV dsr → Test pt)은 Gort et al.의 우려가 reward 변형 선택의 차원에서도 동일하게 나타남을 정량 확인한 것이다.

본 논문의 위치를 한 줄로 요약하면: 기존 DRL 트레이딩 문헌이 단일 reward 함수의 알고리즘/state 설계 비교에 집중한 반면, 본 논문은 같은 알고리즘 (PPO)과 같은 환경 위에서 reward 함수 자체의 4가지 변형을 통제 비교하며, 그 효과를 in-sample / multi-split / OOS 세 환경에서 분리 측정한다.

2.3 Reward 설계 이론

본 논문이 비교하는 4가지 reward 변형은 강화학습과 행동경제학의 세 가지 이론적 계보에서 도출된다. (i) 대칭(sym)은 표준 PnL 수익률 reward로 비교 베이스라인 역할을 한다. (ii) 비대칭(asym)은 손실에 양의 가중치 $\beta > 1$ 을 부여하는 변형으로, 위험 회피 효용 함수의 단순 1차 근사이다. (iii) 미분 샤프 비율(dsr)은 Moody and Saffell [2001]의 정식이다. (iv) 프로스펙트 이론 보상(pt)은 Kahneman and Tversky [1979]과 Tversky and Kahneman [1992]의 효용 함수 $v(x) = \text{sgn}(x)|x|^\alpha$ ($x \geq 0$ 일 때) 또는 $-\lambda|x|^\alpha$ ($x < 0$ 일 때)를 단계 reward로 직접 사용한다.

Moody and Saffell [2001]의 DSR은 샤프 비율의 온라인 추정치 변화량을 step reward로 사용하는 정식으로, 지수 가중 이동 평균(EWMA, decay rate η)으로 1차와 2차 모멘트를 추적한다. 이 정식은 강화학습 정책 학습에 두 가지 의미를 갖는다: (a) 단순 PnL 대비 위험 조정 수익을 직접 최적화한다, (b) sliding window의 메모리 구조가 정책에 단일 step 이상의 시간 의존성을 부여한다. 본 논문 §6은 이 메모리 구조의 결과로 dsr 변형의 정책이 다른 변형 대비 2–6배 긴 holding 시간을 학습함을 정량 확인하며, 이는 §7의 in-sample 다중 분할에서의 우위와 §7.3의 OOS 실패로 이어지는 인과의 출발점이다.

Kahneman and Tversky [1979]의 프로스펙트 이론은 인간 의사 결정의 위험 행동을 설명하는 행동경제학 기초이며, 특히 (a) 손실 회피 $\lambda \approx 2.25$ (Tversky and Kahneman 1992의 표준값), (b) 효용 함수의 오목성 $\alpha \approx 0.88$ 이 핵심 모수이다. 이 이론은 인간 트레이더의 행동(예: “손실에 매달리고 이익은 빨리 실현”)을 설명하는 데는 광범위하게 사용되어 왔으나, 강화학습 정책의 *reward*로 직접 사용한 학술 연구는 매우 드물다. 본 논문은 Kahneman and Tversky [1979]의 정식을 RL reward로 직접 구현하고 ($\alpha = 0.68$, $\lambda = 3.30$, Optuna로 튜닝), 이 reward로 학습된 정책이 분포 외 환경에서 보이는 강건성을 정량적으로 입증한다는 점에서, 본 논문이 알기로는 첫 사례에 해당한다.

Ng et al. [1999]의 정책 불변 reward shaping(potential-based shaping) 정리는 “보상의 단조 변환은 정책 학습 결과에 영향을 미치지 않는다”는 결론을 도출한다. 얼핏 본 논문의 4 reward 변형 비교가 이 정리와 충돌하는 듯 보이지만, 그렇지 않다: sym $\rightarrow$ asym/pt의 변환은 음의 영역에 비대칭 스케일을 부여하는 비-potential-based 변환이며, dsr은 단순 step reward 변환이 아닌 state-extended reward(즉, sliding window 모멘트가 사실상 state의 일부)이다. 따라서 본 논문의 reward 변형 비교는 Ng et al.의 정리의 적용 범위 밖에 있으며, 실제로 변형 간 정책 행동이 통계적으로 유의하게 차이남을 §6에서 확인한다.

2.4 평가 방법론

강화학습 정책의 평가에서 가장 큰 함정은 (a) 백테스트 과적합과 (b) 결과의 시드 의존성이다. Henderson et al. [2018]는 동일 알고리즘이라도 시드 차이만으로 결과가 크게 변동함을 실증하고, 5-10 시드의 통계적 비교, IQM (Interquartile Mean), 부트스트랩 신뢰구간을 표준 권장사항으로 제시했다. 본 논문은 변형당 10 시드(Val/exp033), 100 모델(Test)을 사용하며 페어와이즈 Cohen’s d 와 부트스트랩 $P(A > B)$ 를 모든 비교에 적용한다.

López de Prado [2018] (8장)의 Combinatorial Purged Cross-Validation(CPCV)은 시계열 데이터에서 train/test 누설을 방지하면서 $\binom{N}{k}$ 개의 분할 조합을 활용하여 단일 분할 결과의 일반화 가능성을 강화하는 방법이다. 본 논문은 6-fold CPCV(15 paths)를 §7.2에서 채택한다.

Bailey and López de Prado [2014]의 Deflated Sharpe Ratio(DSR*)는 백테스트 시도 횟수와 분포의 첨도/왜도를 보정한 샤프 비율의 통계적 유의성 검정이다. 본 논문은 CPCV 결과의 다중 비교에 Bonferroni 보정 4-way + DSR* 검정을 함께 사용하며 (§7.2), 모든 reward 변형이 ATR 대비 $p < 0.001$ 의 유의성을 만족함을 확인한다.

본 논문의 평가 방법론 측면 차별점은 세 환경(Val / CPCV / Test)을 동시에 사용하여 winner reversal을 발견한 점이다. 단일 분할 또는 CPCV 단독을 사용하는 기존 연구는 OOS 일반화 실패를 발견할 수 없으며, OOS만 사용하는 연구는 pt 변형의 in-sample 보수성을 발견할 수 없다. 세 환경의 동시 적용은 Henderson et al. [2018]와 Gort et al. [2022]이 권장하는 복수 평가 방식을 reward 변형 비교라는 단일 차원에 일관 적용한 점에서 방법론적 기여를 가진다.

3 방법론

[TBD: 추후 작성. 서브 섹션: §3.1 MDP 설계 (State 7D, Action 2D, ATR 비례 공식), §3.2 Trading 환경 구체 (사이클, fee, slippage), §3.3 4 reward 변형 정의 + Optuna 튜닝 (exp032a), §3.4 PPO 안정화 패키지 (target_kl, ent annealing), §3.5 평가 방법론 (Val/CPCV/Test).]

4 Phase 1: 대칭 보상 하의 정책 포화

[TBD: 추후 작성. *exp020-022*의 " $RL = \text{Fixed}[1.0, 0.0]$ " 발견. 대칭 보상 + ATR 비례 공식 조합의 RL 자유도 흡수. 본 논문의 *reward* 정식화 동기.]

5 Pareto 프론티어와 시나리오 D

[TBD: 추후 작성. *exp032b* 결과: $4 \text{ variants} \times 10 \text{ seeds}$ 통계, *Pareto scatter*, 두 클러스터 (*aggressive/conservative*), 가설 $H1-H3$ 점검, 시나리오 D 확정.]

6 메커니즘 정량화

[TBD: 추후 작성. *exp032c* 결과: *Policy distance* 행렬, *behavior per regime*, *counterfactual action map*, *action distribution*. 인과 사슬: *reward* 형식 $\rightarrow$ 거래 빈도 $\rightarrow$ 클러스터.]

7 강건성 분석

7.1 Slippage 강건성

[TBD: 추후 작성. *exp033*: $4 \text{ variants} \times 10 \text{ seeds}$ with *slippage* 0.02%. *Cluster preservation ratio* $2.19\times$. *ATR-with-slippage fair* 비교 결과 (*Phase 16a*).]

7.2 CPCV 다중 split 평가

[TBD: 추후 작성. *exp034*: 6-fold CPCV 15 paths. *DSR* $p < 0.001$ (Bonferroni 4-way 보정), *dsr* variant reversal 1위 (1.413, 5% CVaR 0.890), *Cluster ratio* $3.55\times$.]

7.3 분포 외 평가와 Prospect Theory의 강건성

[TBD: 추후 작성. 본 논문의 핵심 챕터. *exp035*: 100 RL models + *ATR baseline* + *Buy-and-Hold Test*. *pt*의 *Test* 1위 (두 소스 $p < 0.002$), *dsr*의 *Test* 꼴찌. *Phase 16d mechanism*: holding 시간 분포 (*DSR 7-day max* vs. *pt 6h max*). *pt*의 분포 외 강건성의 인과 사슬.]

8 논의

[TBD: 추후 작성. 서브 섹션: §8.1 *Val-Test* 분포 이동의 정량 ($KS p < 10^{-10}$, -27% variance), §8.2 *exp027_rl* 사전 증거 (*Env-v3 asym 1.955*)의 환경 의존성 정직 인정, §8.3 단일 *metric winner*의 한계, §8.4 한계: *BTC* 단일 자산, *Test 1 regime*, *single slippage level*.]

9 결론

[TBD: 추후 작성. 4개 메인 메시지: (1) *Pareto* 프론티어 *trade-off*, (2) 평가 환경별 *winner reversal*, (3) *Prospect Theory*의 *OOS* 강건성, (4) *In-sample* 우위 $\neq$ *OOS* 강건성. *Future work*: *multi-asset*, *regime*, *DR*, *meta-RL*.]

References

- Marco Avellaneda and Sasha Stoikov. High-frequency trading in a limit order book. *Quantitative Finance*, 8(3):217–224, 2008. doi: 10.1080/14697680701381228.
- David H. Bailey and Marcos López de Prado. The deflated sharpe ratio: Correcting for selection bias, backtest overfitting, and non-normality. *Journal of Portfolio Management*, 40(5):94–107, 2014.
- Charan Bandrupalli. Risk-aware deep reinforcement learning for cryptocurrency and equity trading. *arXiv preprint*, 2025.
- Bryan Gort, Xiao Chen, Matthew Tong, Shaojie Xu, and Xingjian Li. Deep reinforcement learning for cryptocurrency trading: Practical approach to address backtest overfitting. *arXiv preprint arXiv:2209.05559*, 2022.
- Peter Henderson, Riashat Islam, Philip Bachman, Joelle Pineau, Doina Precup, and David Meger. Deep reinforcement learning that matters. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 32, 2018.
- Daniel Kahneman and Amos Tversky. Prospect theory: An analysis of decision under risk. *Econometrica*, 47(2):263–291, 1979. doi: 10.2307/1914185.
- Hao Yuan Timothy Liu. Reinforcement learning trading strategies: A literature review. *arXiv preprint arXiv:2502.06551*, 2025.
- Yang Liu, Qi Liu, Hongke Zhao, Zhenya Pan, and Chuanren Liu. Adaptive quantitative trading: An imitative deep reinforcement learning approach. 34(02):2128–2135, 2020. Referenced as Liu et al. (2021) for the PPO+LSTM Bitcoin trading variant.
- Marcos López de Prado. *Advances in Financial Machine Learning*. Wiley, 2018. Combinatorial Purged Cross-Validation (CPCV), Chapter 7.
- John Moody and Matthew Saffell. Learning to trade via direct reinforcement. *IEEE Transactions on Neural Networks*, 12(4):875–889, 2001. doi: 10.1109/72.935097. Differential Sharpe Ratio (DSR) formulation.
- Andrew Y. Ng, Daishi Harada, and Stuart Russell. Policy invariance under reward transformations: Theory and application to reward shaping. In *Proceedings of the 16th International Conference on Machine Learning (ICML)*, pages 278–287, 1999.
- Minh Pham, Anh Le, and Binh Nguyen. Dqn-based bitcoin technical trading strategy selection. *arXiv preprint*, 2025.
- Siyu Sun, Rundong Wang, and Bo An. Reinforcement learning for quantitative trading. *ACM Transactions on Intelligent Systems and Technology*, 14(3):1–29, 2023. doi: 10.1145/3582560.
- Amos Tversky and Daniel Kahneman. Advances in prospect theory: Cumulative representation of uncertainty. *Journal of Risk and Uncertainty*, 5(4):297–323, 1992. $\alpha = 0.88$, $\lambda = 2.25$ standard parameters.

J. Welles Wilder. New concepts in technical trading systems. 1978.

Hafiz Muhammad Athar Yasin and Asim Anwar Gill. Reinforcement learning framework for quantitative trading. *International Journal of Computer Applications*, 186(8):1–9, 2024.

Zihao Zhang, Stefan Zohren, and Stephen Roberts. Deep reinforcement learning for trading. *The Journal of Financial Data Science*, 2(2):25–40, 2020.