



캡스톤 프로젝트 중간 보고서

BTC 동적 그리드 트레이딩: ATR 규칙 기반 vs 강화학습

작성일: 2026-04-24

실험 범위: exp001 ~ exp029

목차

1. 프로젝트 개요
2. 시스템 구조 한눈에 보기
3. 실험 전체 흐름
4. 현재 상태 및 결론
5. 앞으로 방향

1. 프로젝트 개요

핵심 아이디어

가격이 오를지 내릴지 예측하지 않는다. 대신 변동성 자체에서 수익을 추구하는 동적 그리드 트레이딩을 구현한다.

그리드 트레이딩 원리:

현재가 \$100 기준으로 주문 배치:

```
$108 ← sell_cost   (평단가 기준 목표 수익)
$105 ← sell_market (현재가 기준 목표 수익)
$100 ← 현재가
$96  ← buy_market  (첫 진입)
$90  ← buy_avg     (물타기 DCA)
```

→ 가격이 오르내리며 주문이 반복 체결 = 수익 누적

핵심 질문: 그리드 간격을 고정 규칙(ATR 비례)으로 결정하는 것 vs 강화학습(PPO)으로 학습하는 것 — 어느 쪽이 더 나은가?

2. 시스템 구조 한눈에 보기

2-1. 데이터 파이프라인

소스: Binance API (ccxt) — BTC/USDT 1시간봉

```
Binance API
  | ccxt (download_data.py)
  ▼
data/raw/btc_1h.parquet      ← 원본 OHLCV (불변)
  | preprocess_data.py
  ▼
data/processed/
  ├── btc_train.parquet  — Train  2017-08-17 ~ 2022-12-31  (44,952봉)
  ├── btc_val.parquet   — Val    2023-01-01 ~ 2023-12-31  (8,760봉)
  └── btc_test.parquet   — Test   2024-01-01 ~ 현재      (불인)
```

전처리 후 컬럼:

컬럼	계산식	역할
close , high , low	원본	주문 체결 판단

컬럼	계산식	역할
atr_168	Wilder ATR(168봉)	변동성 스케일
atr_ratio	atr_168 / close	정규화된 변동성
log_price	log(close / close.rolling(168).mean())	중기 가격 위치
trend_72h ~ trend_1440h	pct_change(N)	방향성 피쳐 5종
zscore_*	(x - x.rolling(168).mean()) / std	모든 state 변수 정규화

데이터 기간 설계 근거:

구간	기간	주요 레짐	역할
Train	2017~2022	BULL/BEAR/SIDE 혼재, 2022 대폭락(-64%) 포함	다양한 시장 학습
Val	2023	회복 + H2 BULL (30k→44k)	하이퍼파라미터 튜닝
Test	2024~	ETF 승인, 반감기, 강한 상승	최종 평가 (봉인)

2-2. 체결 로직

한 봉(1시간)에서 처리 순서:

봉 정보 수신: open, high, low, close

|

▼

1. SELL 주문 체결 판단 (Sell-First 원칙)

└─ sell_market: next_high >= sell_market → 체결

└─ sell_cost: next_high >= sell_cost → 체결

|

▼

2. BUY 주문 체결 판단

└─ buy_market: next_low <= buy_market → 체결

└─ buy_avg: next_low <= buy_avg → 체결

|

▼

3. 청산 룰 (하드 룰)

if holdings_value < cycle_slot_size:

→ sell_market 전량 매도 강제 실행

|

▼

4. State 업데이트 + Reward 계산

Sell-First 원칙: 같은 봉에서 buy·sell 동시 체결 가능 시 sell을 먼저 처리. 매수 직후 매도 → 수수료만 손실하는 허위 수익 방지.

수수료: Binance 지정가 maker fee 0.05% per trade (매수/매도 각각 적용)

사이클 정의:

사이클 시작: holdings == 0 → 첫 buy 체결 순간

사이클 진행: 매수/매도 반복 (n_splits 슬롯 기준 예산 관리)

사이클 종료: holdings → 0 (전량 매도 완료)

2-3. 최종 환경 구조 (exp029 기준)

State (9차원, rolling z-score 정규화)

STATE (9D)		
0	zscore_log_price	현재가 vs 7일 이동평균 위치
1	divergence	평단가 대비 현재가 괴리율
2	holdings_value_ratio	보유 BTC 가치 / 초기 자본
3	cash_ratio	현금 / 초기 자본
4	zscore_volatility	ATR(168h) / price
5	zscore_trend_72h	3일 단기 모멘텀
6	zscore_trend_720h	30일 중기 레짐
7	idle_norm	미거래 경과시간 / grace_period
8	n_splits_norm	현재 사이클 분할 수 (정규화)

Action (5차원 연속 [0,1]⁵, 사이클 시작 시 1회 결정)

ACTION (5D)		
사이클 시작 순간 한 번만 결정, 이후 고정		
0	n_splits_coef	$n_splits = 5 + \text{round}(a \times 10) \rightarrow \{5..15\}$
1	gap_b1	$\text{buy_market} = \text{price} \times (1 - \text{atr} \times a \times \text{coef})$
2	gap_b2	$\text{buy_avg} = \text{last_avg} \times (1 - \text{atr} \times a \times \text{coef})$
3	gap_s1	$\text{sell_market} = \text{price} \times (1 + \text{atr} \times a \times \text{coef})$
4	gap_s2	$\text{sell_cost} = \text{avg} \times (1 + \text{atr} \times a \times \text{coef})$

coef_b1=9.9, coef_b2=9.5, coef_s1=9.7, coef_s2=23.9 (Optuna 최적값)

Reward (3성분)

```

r_step = (equity_t - equity_{t-1}) / start_capital # 매 스텝, symmetric
r_cycle = cycle_return_pct × w_cycle # 사이클 완료 보너스
r_idle = -idle_rate × (cash / start_capital) # idle > grace_period 시 패널티

reward = r_step + r_cycle + r_idle

```

3. 실험 전체 흐름

exp001	exp016	exp023	exp027	exp029
[P1]	[P2]	[P3]	[P4]	
0.8	35x	현실화	1.955	-0.450
Sharpe	버블	붕괴	최고	과적합

Phase 1: 기반 구축 (exp001~016) — 2026-04-05 ~ 04-21

exp001 — 첫 PPO 학습

문제: MDP 설계가 이산(Buy/Sell/Hold) 에서 시작 → 방향성 트레이딩 접근.
변경: 연속 2D action [aggressiveness, profit_target]으로 설계 변경. 그리드 트레이딩으로 전환.
결과: Val Sharpe 0.795. 기준선 대비 낮음.

exp002~010 — 순차적 개선

실험	변경	문제	결과
exp002~005	수수료 계산, state 정규화	이중 계산 버그	수정 후 Sharpe 개선
exp006~010	n_splits 도입, 사이클 보너스	reward sparse	구조 안정화

exp011~015 — ATR 비례 공식 도입

문제: 절대 간격(예: 5%) → 변동성 낮을 때 체결 안 됨, 높을 때 과도한 손실.
변경: `gap = atr_ratio × action` — 변동성에 비례하는 동적 간격.
결과: 체결 확률 스펙트럼이 [0,1] 전체에 고르게 분포됨.

exp016 — Bayesian 최적화

문제: ATR 공식의 계수(coef)를 수동 설정.
변경: scikit-optimize Bayesian 50 trials로 `coef_b1, coef_b2, coef_s1, coef_s2` 최적화.
결과: Val Sharpe **35.424**, Test Sharpe **43.040** — 베이스라인(1.472)의 29배.

```

||  △ PIVOT 1 - "Sharpe 수조%" 버블 붕괴 ||
||                                     ||
||  43배 우위는 구조적 artifact였다. ||
||  행동 분석: 결정론적 행동이 항상 [0.0, 0.0]으로 수렴. ||
||  Bayesian이 A_s=0.101(탐색 하한)으로 수렴 → RL action 역할 제거. ||
||  실제 의미: 봉의 최저가 매수 / 최고가 매도 (비현실적 체결). ||

```

핵심 교훈: 시뮬레이터가 "봉의 고점/저점에서 체결"을 허용하면 RL이 이를 exploit. 체결 로직을 지정가(limit order) 로 현실화해야 한다.

Phase 2: 재설계 + 현실화 (exp017~023) — 2026-04-21 ~ 04-22

exp017~018 — 데이터 재분할 + 지정가 체결

문제: Val(2020 BULL만)이 Test 레짐과 불일치. 체결 로직 비현실적.

변경:

- Val 기간을 2021~2023으로 교체 (ATH→대 폭락→회복 포함)
- 체결 조건: `next_low <= buy_price` , `next_high >= sell_price` (지정가)

결과: Val Sharpe 38.186 (여전히 높지만 현실에 가까워짐).

exp019~021 — Action 구조 Ablation

목적: RL이 실제로 학습하는가, 아니면 고정값으로 수렴하는가 검증.

실험	변경	결론
exp019	<code>n_splits</code> action으로	4로 수렴 (고정값)
exp020	<code>budget_fraction</code> action으로	1.0으로 수렴 (항상 전체 예산)
exp021	<code>entry_gate</code> action으로	open으로 수렴 (항상 진입)

```

|| Δ PIVOT 2 - "ATR이 이미 레짐 적응을 하고 있다" ||
||
|| 결정적 실험: Fixed [1.0, 0.0] vs RL(exp020) ||
|| → Val Sharpe 45.390 vs 45.390 - 완전 동일 ||
||
|| ATR/price 비례 공식이 변동성 레짐을 이미 내재 처리. ||
|| RL이 추가로 배울 신호가 gap 크기에 없다. ||
|| → RL의 역할을 "gap 계수"가 아닌 다른 것으로 재정의해야 함. ||

```

exp022~023 — ATR 단독 성능 재평가

문제: Sharpe 수조% 시대의 계수들을 지정가 체결 환경에서 재검증.

변경: Bayesian 최적화를 지정가 환경에서 재실행.

결과:

	Val Sharpe	Test Sharpe
구 계수 (exp022)	60.723 → 정규화 1.701	0.935
새 계수 (exp023)	재최적화	1.701 유지

Sharpe 수조% → Val 1.701 / Test 0.935 로 현실화. 이것이 진짜 기준선.

Phase 3: ATR vs RL 공정 비교 (exp024~027) — 2026-04-22 ~ 04-23

exp024~026 — RL 재설계 (지정가 환경 대응)

문제: 이전 RL 설계가 비현실적 체결 환경 기준. 지정가 환경에서 재학습 필요.

변경:

- State 7D (trend_72h, trend_720h 추가)
- Action 4D (buy_hi, buy_lo, sell_market, sell_cost 계수)
- Reward: symmetric equity change

exp026 Val Sharpe: 0.896 (ATR 1.701 미달)
exp026 Test Sharpe: 0.009

그러나 레짐별 행동 분석에서 중요한 발견:

Action	Bull	Bear	해석
buy_hi_coef	0.235	0.328	하락장: 더 보수적 진입
sell_m_coef	0.011	0.001	하락장: 손절 방지 (Sharpe p<0.001)
sell_c_coef	0.229	0.160	상승장: 더 높은 목표가 설정

→ RL이 State에서 레짐을 감지하고 다르게 행동하는 것을 학습했다 (K-W p<0.001).

exp027 — ATR + Direction Rule vs RL

배경: RL이 방향성을 활용한다면, 수동 direction rule로 동일 효과를 낼 수 있는가?

```
# ATR+direction rule
buy_mult  = 1.0 + k × max(0, -trend_raw)  # 하락 → buy gap 확대
sell_mult = 1.0 + k × max(0,  trend_raw)  # 상승 → sell gap 확대
```

Optuna 최적화 → trend_window=336h, k=3.584

	Val Sharpe	Test Sharpe	판정
ATR (exp026)	1.701	0.935	규칙 기반 기준
ATR+direction	2.348	-0.213	Val 과적합 (k 고정)
RL exp027 best	2.444	1.955	현재 최고 성능

exp027 RL 분석:

- Test Sharpe **1.955** — ATR의 2.1배
- Test MDD **0.39%** — 극도로 낮은 낙폭
- 거래 **214건** — ATR(1,591건)의 1/7, 선택적 진입

성공 원인: asymmetric reward(beta=2.0)가 "확신 없으면 거래 마라"를 유도. trend_720h +

volatility 결합으로 유망한 사이클만 선별.

```
△ PIVOT 3 - "거래 안 함" 붕괴 + 재현성 없음
exp027 RL best (200k step): Test Sharpe 1.955 ← 성공
exp027 RL final (1M step): 거래 0건, Sharpe 0.000 ← 붕괴
asymmetric beta=2.0의 역설:
손실 패널티가 커질수록 "거래 안 함(reward=0)"이 최적 전략.
best_model이 200k에 우연히 저장됐을 뿐, 재현성 없음.
→ 보상 구조 자체를 바꿔야 한다.
```

Phase 4: 전면 재설계 (exp028~029) — 2026-04-23 ~ 04-24

exp028 — 학습 안정화 시도

문제: beta=2.0이 너무 강함 → 거래 회피 수렴.

변경: beta: 2.0 → 1.5 + early stopping(patience=6) 추가.

결과: 동일 패턴. beta 조정만으로는 해결 불가.

핵심 인사이트: beta 값 자체가 문제가 아니라 reward 구조가 "거래 안 함"을 허용하는 한 같은 결과.

exp029 — MDP 전면 재설계

3가지 근본 문제 해결 시도:


문제	exp029 해결책
"거래 안 함" 붕괴	asymmetric beta 제거 + idle penalty 도입
RL action 역할 불분명	사이클 시작 시 1회 결정 (n_splits + 4 gap 계수)

문제	exp029 해결책
Val/Test 레짐 불일치	Val 기간 2023-12-31까지 확장

3단계 Optuna:

단계	대상	Trials	최적 Val Sharpe
1단계	PPO 하이퍼 파라미터	30 × 200k	1.786
2단계	환경 파라미터	50 × 200k	2.019
3단계	전체 최적값으로 1M 학습	—	1.440 (best, 450k)

학습 곡선:



```

||  △ PIVOT 4 - "Val 최적화 = Test 과적합" ||
||
|| exp029 결과: ||
||   Val Sharpe +1.440 (baseline 1.051 초과 ✓) ||
||   Test Sharpe -0.450 (baseline 1.463 대비 완패 X) ||
||
|| 원인: ||
|| Optuna를 Val에 3번 적용 → Val(혼재장, 2021~2023) 메타 과적합. ||
|| Test(2024~, 강한 상승장)는 Val과 완전히 다른 레짐. ||
|| → 더 단순한 exp027 RL(Test 1.955)보다 오히려 퇴보. ||

```

4. 현재 상태 및 결론

전략별 최종 성적표

전략	Val Sharpe	Test Sharpe	Test MDD	비고
Buy-and-Hold	0.373	0.734	77.2%	기준
Fixed Grid 1%	0.190	0.242	42.2%	
Fixed Grid 5%	1.051	1.463	1.3%	Test 베이스라인 최고
ATR k=1.0	1.701	0.499	28.9%	
ATR+direction	2.348	-0.213	3.4%	Val 과적합
RL exp027 best	2.444	1.955	0.39%	RL 최고
RL exp029 best	1.440	-0.450	19.9%	Val 과적합

핵심 발견 4가지

발견 1: **ATR** 비례 공식의 암묵적 레짐 적응

ATR/price가 변동성 레짐을 이미 내재 처리 → RL이 gap 크기에서 추가 학습 여지 없음.
"Fixed [1.0, 0.0] = RL" (exp020) 실험이 증거.

발견 2: 고정 규칙의 Val 과적합 한계

$k=3.584$ 같은 고정 계수는 Val 레짐에서 최적이지만 Test에서 역효과.
direction rule(Val 2.348 → Test -0.213)이 대표적 사례.

발견 3: asymmetric reward의 구조적 역설

손실 패널티가 강할수록 "거래 안 함(reward=0)"이 최선 전략이 됨.
beta 조정이 아니라 reward 구조 자체를 바꿔야 해결 가능.

발견 4: RL의 state 기반 레짐 적응 성공 (exp026/027)

레짐별 행동이 통계적으로 유의미하게 다름 (K-W $p<0.001$).
고정 공식이 포착 못하는 방향성 신호를 RL이 활용.
Test Sharpe 1.955 — ATR의 2.1배.

현재 상태 진단

달성: RL이 ATR을 상회하는 성능 달성 가능함을 증명 (exp027, Test 1.955)
미달: 안정적 재현 불가. exp029에서 오히려 퇴보.
원인: 레짐 불일치 + Val 과적합 + 학습 불안정의 복합 문제

5. 앞으로 방향

진단

exp029의 실패는 세 가지가 동시에 문제였다:

1. 훈련 데이터 레짐 편향 — Train(2017~2020)에 BULL 상승장 비중 부족
2. Reward 노이즈 — 매 스텝 equity 변화는 신호가 약함
3. Optuna 과도 적용 — Val에 3번 최적화 = Val 메타 과적합

변경 계획

[변경 1] 훈련 데이터 재조정 — 레짐 균형

현재:	Train 2017-2020		Val 2021-2023		Test 2024~
변경:	Train 2017-2022		Val 2023		Test 2024~
	↑		↑		
	BULL(2020, 2021)		회복+H2 BULL		
	BEAR(2018, 2022)		→ Test와 레짐 가깝		
	모두 Train에 포함				

효과: Test(강한 상승장)와 비슷한 레짐(2020 BULL, 2021 ATH)을 Train에 포함 → 일반화 향상.

[변경 2] Reward 재설계 — Rolling Sharpe

```
# 현재 (노이즈 많음)
reward = (equity_t - equity_{t-1}) / start_capital

# 변경: 최근 N봉의 Sharpe를 직접 최적화
window = 168 # 7일
returns = equity_history[-window:].pct_change().dropna()
reward = returns.mean() / (returns.std() + 1e-8)
```

효과: "얼마나 벌었나"가 아니라 "얼마나 안정적으로 벌었나"를 직접 최적화. 학습 목표(Sharpe)와 reward 신호 정렬.

[변경 3] 단순화 — 복잡도 줄이기

5D action → 3D 또는 2D 검토. exp027이 증명했듯 단순한 설계가 더 잘 일반화.

기대 효과

변경	기대 효과
Train 확장	Test 레짐 경험 → Val→Test 일반화 갭 감소
Rolling Sharpe reward	학습 안정화 + 목표-reward 정렬
단순화	과적합 방지, 학습 효율 향상

장기 (2학기)

과제	내용
다자산 확장	주식(AAPL, SOXL), 외환, 원자재에서 ATR vs RL 비교
Live Trading	Binance Testnet → 실제좌 소액
논문 작성	"ATR 비례 그리드 vs RL — 자산군별 우위 조건"

핵심 가설 (2학기): BTC에서는 $ATR \approx RL$ 이었지만, 이벤트 리스크(실적 발표, 금리 결정)가 있는 자산에서는 RL의 state 기반 적응이 ATR을 이길 수 있다.

실험 상세 기록: [RESEARCH_LOG.md](#)

환경 설계: [src/env/trading_env.py](#)

설정 파일: [config/experiment_config.yaml](#)