

캡스톤 디자인 주제 제안서 (v3.0)

PPO 기반 비트코인 동적 그리드 트레이딩 에이전트 학습 및 행동 패턴 분석

2026년 4월

1. 연구 주제

가격 방향 예측 없이 시장 상태(변동성·가격 수준)와 포지션 상태(손익·보유량·여력)만을 **state**로 사용하는 PPO 기반 강화학습 에이전트의 비트코인 동적 그리드 트레이딩 전략 학습 및 행동 패턴 분석

2. 연구 배경 및 동기

금융 시장은 본질적으로 비정상적(non-stationary)이며, 변동성과 불확실성이 높아 정적 규칙 기반 전략이 실패하기 쉬운 환경이다. 2018~2025년 RL 트레이딩 연구를 종합한 Liu(2025)는 RL 기반 전략이 비정상 시장에서 전통 전략 대비 높은 적응성을 보임을 확인하였다. 그러나 Sun et al.(2023)은 해석가능성 부족과 시장 레짐 간 일반화가 분야 전반의 미해결 과제를 지적하였다.

기존 알고리즘 트레이딩 연구의 주류는 LSTM 등 딥러닝으로 미래 가격을 예측한 뒤 그 예측값을 기반으로 매수·매도 방향을 결정하는 방향성 트레이딩(directional trading)이다. 그러나 이 접근법은 두 가지 근본적 문제를 가진다.

- 예측 오류의 전파: 가격 예측이 틀리면 트레이딩 결정도 틀린다. 두 모델의 오류가 누적된다.
- 시장의 본질적 불확실성: 비트코인처럼 변동성이 극단적인 자산에서 단기 가격 예측의 신뢰도는 매우 낮다.

본 연구는 이 문제의식에서 출발한다. 가격 방향을 예측하는 대신, 가격 변동성 자체에서 수익을 추구하는 그리드 트레이딩(grid trading) 구조를 채택한다. 그리드 트레이딩은 미리 설정한 간격으로 매수·매도 지정가 주문을 배치하여 가격이 오르내릴 때마다 수익을 누적하는 전략이다. 핵심은 방향이 아니라 변동성이다.

기존 그리드 봇은 간격을 사람이 고정 설정하므로 시장 레짐 변화에 적응하지 못한다. 본 연구는 PPO 에이전트가 현재 시장 상태에 반응하여 그리드 간격과 익절 목표를 동적으로 결정하도록 학습시킨다. 에이전트가 언제 좁은 간격으로 적극적으로 매수하고 언제 넓은 간격으로 보수적으로 운용하는지를 분석하는 것이 본 연구의 핵심 기여다.

3. 연구 질문

주 질문: 시장 상태와 포지션 상태에 반응하여 그리드 간격과 익절 목표를 동적으로 결정하는 PPO 에이전트가 비트코인 시장에서 고정 그리드 전략 대비 Sharpe Ratio 기준 우위를 보이는가?

부 질문: 학습된 에이전트는 어떤 시장 상태(변동성 수준, 가격 수준)에서 어떤 그리드 간격 (aggressiveness)과 익절 목표(profit_target)를 선택하는가?

4. 선행 연구 및 차별점

관련 선행 연구 7편을 두 그룹으로 분류하여 검토하였다.

그룹 1 — 분야 배경

기존 방향성 RL 트레이딩의 한계와 본 연구의 필요성을 정당화하는 배경 논문들이다.

논문	내용	본 연구에서의 역할
Sun et al. (2023) ACM Survey	RL 기반 트레이딩 전반 조망. DQN·PPO가 전통 전략 대비 우위를 보이나 해석가능성 부족과 시장 레짐 간 일반화가 미해결 과제	방향성 RL의 한계를 정의하는 근거. 본 연구가 이 공백을 비방향성 그리드 구조로 접근하는 배경
Liu H.Y.T. (2025) 리뷰 논문	2018~2025년 10편 종합. RL이 비정상 시장 적응성에서 우위 확인. 훈련 안정성·샘플 효율성이 실전 적용의 주요 장애물	분야 흐름과 한계를 뒷받침하는 근거

그룹 2 — 직접 선행 연구

본 연구의 차별점을 가장 직접적으로 정의하는 논문들이다.

논문	방법론	한계	본 연구와의 차별점
Liu et al. (2021)	PPO + LSTM 가격 예측 → state 입력	예측 오류가 트레이딩 결정에 전파되는 2단계 파이프라인	예측 단계 완전 제거. 가격 방향 무관한 그리드 구조 채택
Yasin & Gill (2024)	DQN/PPO/A2C + 기술지표 20개 비교	홀드 행동 없음. 현재 포지션 미포함. 과매매 억제 불가	연속 행동 공간(간격 값) 사용. 포지션 상태(손익·보유량)를 state에 반영
Pham et al. (2025)	DQN + 5개 사전정의 전략 선택	매수/매도 조건이 전략 내부에 하드코딩. PCA로 지표 원형 손실	전략 없이 그리드 간격을 직접 학습. 지표 원형 유지로 행동 분석 가능
Bandarupalli (2025)	PPO + 변동성 패널티 + 거래비용	과도한 리스크 패널티로 수익 기회 억제. Buy-and-Hold 하회	변동성 패널티 제외. 거래비용 패널티와 사이클 수익 신호만 사용

설계 반영 — Gort et al.(2022)

Gort et al.(2022)은 DRL 트레이딩 연구 대부분이 단일 검증셋 사용으로 백테스트 과적합을 보고함을 실증하였다. 본 연구는 이를 반영하여 테스트셋을 학습 전 과정에서 봉인하고 다양한 시장 레짐에 걸친 검증 구간을 설계하였다.

핵심 차별점 요약

- 가격 방향 예측 단계를 완전히 제거하고 변동성 기반 그리드 수익 구조를 채택한다. Liu et al.(2021)의 예측 의존 파이프라인과 구별된다.
- 이산 행동(Buy/Sell/Hold) 대신 연속 행동 공간(**aggressiveness**, **profit_target**)으로 그리드 간격을 직접 학습한다. Pham et al.(2025)의 메타-전략 선택 구조와 구별된다.
- 포지션 상태(손익·보유 규모·현금 여력)를 **state**에 반영하여 에이전트가 자신의 재무 상태를 인식하고 행동하도록 설계한다. Yasin & Gill(2024)의 포지션 미반영 구조와 구별된다.

5. 시스템 설계 및 실험 설계

5-1. 환경 설계 (MDP 정의)

구성 요소	내용
State (5차원)	- $\log_price = \log(price / price.rolling(168).mean())$ — 시장 가격 수준 - $divergence = (avg_price - price) / avg_price$ — 평단 대비 손익 (미보유 시 0) - $holdings_value_ratio = (holdings \times price) / start_capital$ — 포지션 규모 - $cash_ratio = cash / start_capital$ — 매수 여력 - $volatility = ATR(168) / price$ — 상대적 변동성 → 전처리: rolling z-score (window=168) 정규화
Action (2차원 연속)	- $aggressiveness \in [0, 1]$ $buy_hi_gap = 0.0001 + aggressiveness \times 0.05 \rightarrow [0.01\%, 5\%]$ $buy_lo_gap = 0.001 + aggressiveness \times 0.10 \rightarrow [0.10\%, 10\%]$ - $profit_target \in [0, 1]$ $sell_lo_gap = 0.0001 + profit_target \times 0.05 \rightarrow [0.01\%, 5\%]$ $sell_hi_gap = 0.001 + profit_target \times 0.15 \rightarrow [0.10\%, 15\%]$ - 주문 4개 고정: buy_hi, buy_lo (현재가 기준) / $sell_lo, sell_hi$ (평단가 기준) - 체결 판단: 다음 봉 $high \geq sell_lo \rightarrow sell$ 체결 / 다음 봉 $low \leq buy_hi \rightarrow buy$ 체결
Reward	- 매 스텝: $(equity_t - equity_{t-1}) / start_capital - fee \times n_trades$ - 사이클 종료 시 추가: $cycle_pnl_pct + \alpha / cycle_hours$ fee_rate: 0.05% (Binance maker fee 기준) - 사이클 정의: $holdings == 0 \rightarrow$ 첫 체결 시 시작 / $holdings \rightarrow 0$ 복귀 시 종료 - α (cycle_alpha): 빠른 회전 보너스 가중치, 초기값 0.5 (Val 셋 튜닝 예정)
알고리즘	PPO (Proximal Policy Optimization) — stable-baselines3 라이브러리 MlpPolicy (연속 행동 공간, tanh 출력 $\rightarrow [0, 1]$ 스케일링) 2학기 확장: PPO $\rightarrow$ SAC (off-policy, 연속 행동에 더 적합)

5-2. 데이터 설계

구분	기간	용도
Train	2020.01 — 2022.12 (3년)	에이전트 학습. 상승·하락·횡보 레짐 포함
Validation	2023.01 — 2023.12 (1년)	하이퍼파라미터 튜닝 (cycle_alpha 등)
Test	2024.01 — 현재 (봉인)	최종 성능 평가 — 학습 전 과정에서 열람 금지

데이터 소스: Binance API (ccxt 라이브러리) BTC/USDT 1시간봉. yfinance는 최근 730일까지만 1h 데이터를 제공하므로 학습 기간 전체를 커버하기 위해 거래소 API 직접 사용.

테스트셋 봉인은 Gort et al.(2022)이 지적인 백테스트 과적합 문제 방지를 위한 설계다.

5-3. 실험 설계

비교 그룹

PPO 에이전트의 성능을 세 가지 베이스라인과 비교한다.

비교 대상	설명	비교 목적
Buy-and-Hold	BTC 단순 보유 전략	절대 기준선. 그리드 전략 자체가 의미 있는가
고정 그리드 봇 (1%, 2%, 5%)	간격을 고정한 기계적 그리드 전략	RL의 동적 간격 학습이 고정 간격보다 나은가 (주 질문의 핵심 비교)
ATR 비례 그리드 봇 (k=0.5, 1.0, 2.0)	$gap = k \times (ATR_{168} / price)$ 규칙 기반 적응 전략	같은 변동성 정보를 규칙으로 쓰는 것보다 학습으로 쓰는 것이 나은가

고정 그리드와 ATR 비례 그리드를 베이스라인으로 설정하는 이유: 에이전트의 state에 ATR 기반 변동성 지표가 포함된다. RL이 이 정보를 학습해서 쓰는 것이 규칙으로 고정해서 쓰는 것보다 나은지를 직접 검증한다.

평가 지표

지표	설명
Sharpe Ratio	주 평가 기준. 리스크 조정 수익률
누적 수익률	Buy-and-Hold 대비 초과 수익 여부
MDD (Maximum Drawdown)	최대 낙폭. 리스크 지표
평균 사이클 수익률	사이클당 평균 pnl_pct. 그리드 효율성 지표
평균 사이클 시간 (시간)	사이클 완료까지 평균 소요 시간
거래 횟수	과매매 여부 확인

행동 패턴 분석 — 부 질문 검증

분석 항목	방법
변동성 수준별 aggressiveness 분포	산점도 / 히스토그램
가격 수준별 profit_target 분포	산점도 / 히스토그램
사이클 수익률 vs 진입 시점 변동성	박스플롯
레짐별 행동 전략 요약	레짐 구간 분류 후 행동 통계 비교

5-4. 2학기 확장 계획

항목	내용
Ablation study	state 구성요소(log_price, divergence, holdings_value_ratio, cash_ratio, volatility)를 하나씩 제거하며 성능 변화 측정. 각 변수의 기여도 정량화
SAC 전환	PPO → SAC (Soft Actor-Critic). off-policy 알고리즘으로 연속 행동 공간에서 샘플 효율성 향상. State, 환경 체결 로직, Reward 재사용. 출력층만 교체
주문 개수 가변화	buy 2개·sell 2개 고정 → 개수 가변. n_orders를 action의 일부로 학습하거나 config로 제어하여 그리드 복잡도 적응
멀티 자산 적용	BTC에서 학습한 에이전트를 ETH 등 타 자산에 적용. 일반화 가능성 검증

6. 1 학기 실행 계획

기간	목표	산출물
3~4월	데이터 파이프라인 + Gymnasium 환경 구현	ccxt 다운로드 스크립트, ATR/log_price 전처리, trading_env.py, env_checker 통과
4~5월	베이스라인 구현 + PPO 학습 + 기초 비교 실험	고정 그리드·ATR 그리드 구현, PPO 학습 곡선, Val 셋 Sharpe 비교표
5~6월	행동 패턴 분석 + 중간 보고서	aggressiveness/profit_target vs 시장 레짐 분석 그래프, 중간 보고서

7. 결론

본 연구는 '예측이 아닌 반응'이라는 명확한 철학 위에 설계된 강화학습 트레이딩 시스템이다. 가격 방향 예측에 의존하는 기존 연구들의 공통 한계에서 출발하여, 변동성 자체에서 수익을 추구하는 동적 그리드 트레이딩 구조를 PPO 에이전트로 구현한다.

선행 연구들이 공통으로 남긴 공백 — 예측 의존 파이프라인 제거, 연속 행동 공간의 직접 학습, 포지션 상태를 반영한 state 설계, 행동 패턴의 실증적 분석 — 을 채우는 것과 1학기 내에 작동하는 시스템과 베이스라인 대비 비교 실험 결과를 도출하는 것을 목표로 한다.